بسمه تعالی



دانشگاه اصفهان

دانشکده‌ی فیزیک

گزارش پروژه‌ی کارشناسی فیزیک (۳ واحد)

طراحی و پیاده‌سازی سامانه‌ی بازیابی هوشمند اطلاعات و استخراج خواص فیزیکی مواد از مقالات علمی

با معماری RAG و پایگاه داده‌های برداری

پژوهشگر:

امین حسین سدیدی

استاد راهنما:

دکتر محمدی

شماره‌ی دانشجویی:

۴۰۲۴۲۱۳۰۲۷

آبان ۱۴۰۵

سپاسگزاری

از استاد راهنمای گرامی، دکتر محمدی، که با راهنمایی‌ها و پیشنهادهای ارزشمندشان در تعریف موضوع و مسیر این پروژه یاری‌ام کردند، صمیمانه سپاسگزارم.

این پروژه بر پایه‌ی ابزارها و داده‌های آزادی بنا شده است که جامعه‌ی علمی در دسترس همگان گذاشته است؛ به‌ویژه پایگاه داده‌ی refractiveindex.info، پایگاه HITRAN، کتابخانه‌ی Docling، مدل برداری BGE و پایگاه‌های داده‌ی برداری ChromaDB و Qdrant.

اظهارنامه

اینجانب امین حسین سدیدی، دانشجوی کارشناسی فیزیک دانشگاه اصفهان به شماره‌ی دانشجویی ۴۰۲۴۲۱۳۰۲۷، گواهی می‌کنم که طراحی و اجرای این پروژه را خود انجام داده‌ام و در استفاده از نتایج پژوهش دیگران، منبع را ذکر کرده‌ام. در نوشتن بخشی از کد و ویرایش متن از دستیارهای هوش مصنوعی استفاده شده است؛ طراحی، تصمیم‌ها، آزمون‌ها و درستی‌آزمایی نتایج بر عهده‌ی اینجانب بوده است.

امضا: _____

چکیده

داده‌های پایه‌ی فیزیک مواد، مانند فرمول پاشندگی ضریب شکست، ضرایب غیرخطی مرتبه‌ی دوم، ضریب ترمواپتیک و پارامترهای خطوط طیفی، در جدول‌ها و معادله‌های هزاران مقاله پراکنده‌اند و مدل‌های زبانی عمومی این مقادیر را اغلب بدون منبع قابل‌اتکا تولید می‌کنند. در این پروژه سامانه‌ای با معماری «تولید تقویت‌شده با بازیابی» (RAG) طراحی و پیاده‌سازی شد که مقاله‌های PDF را به متن و جدول ساختاریافته تبدیل می‌کند، آن‌ها را در پایگاه داده‌های برداری (ChromaDB و Qdrant) نمایه می‌کند و به پرسش فارسی یا انگلیسی با ارجاع به مقاله، صفحه و محل روی صفحه پاسخ می‌دهد. بازیابی ترکیبی از جست‌وجوی معنایی با مدل bge-base-en-v1.5 و جست‌وجوی کلیدواژه‌ای BM25 است که با روش ادغام معکوس رتبه (RRF) یکی می‌شوند. استخراج ساخت‌یافته‌ی خواص با سه بررسی خودکار ضدتوهم همراه است.

سامانه نخست روی طیف‌سنجی مولکولی با مرجع HITRAN آزموده و سپس به بلورهای اپتیک خطی و غیرخطی گسترش داده شد. مجموعه‌ی نهایی ۲۸۴۵ سند و ۶۸۱۹۰ بخش قابل‌جست‌وجو دارد. در آزمون HITRAN، پاسخ RAG با مدل محلی Qwen3-4B در ۱۴ پرسش از ۱۵ پرسش مقدار درست را آورد، در حالی که همان مدل بدون منبع در هیچ پرسشی پاسخ درست نداد. در ارزیابی ۲۰۰ پرسش طلایی، MRR@10 برای جست‌وجوی ترکیبی ۰/۵۱۸ و پس از رتبه‌بندی دوم ۰/۵۹۰ بود. بر این پایه، یک پایگاه داده‌ی فیزیکی آزموده و محاسبه‌گرهای تطبیق فاز و تولید جفت فوتون ساخته شد که خروجی‌شان با مقادیر گزارش‌شده در مقاله‌های اصلی هم‌خوان است؛ برای نمونه، زاویه‌ی تطبیق فاز تولید هماهنگ دوم نوع اول در بلور BBO در طول موج ۱/۰۶۴ میکرومتر ۲۲/۸۳ درجه به دست آمد که با مقدار ۲۲/۸ درجه‌ی ادبیات هم‌خوان است. نتیجه‌ی منفی مهم پروژه این است که استخراج کاملاً خودکار ضرایب فرمول با مدل زبانی به دقت لازم نرسید و داده‌ی دقیق فقط با استخراج نیمه‌دستی و آزمون در برابر خود مقاله به دست آمد.

واژگان کلیدی: تولید تقویت‌شده با بازیابی، پایگاه داده‌ی برداری، بازیابی ترکیبی، استخراج خواص مواد، ضریب شکست، اپتیک غیرخطی، تطبیق فاز.

فهرست مطالب

چکیده ۳

۱ مقدمه ۱۰

۱.۱ بیان مسئله ۱۰

۲.۱ اهداف ۱۱

۳.۱ پرسش‌های پژوهش ۱۲

۴.۱ نوآوری و دامنه‌ی کار ۱۲

۵.۱ ساختار گزارش ۱۳

۲ مبانی نظری و پیشینه ۱۴

۱.۲ مدل‌های زبانی و معماری RAG ۱۴

۱.۱.۲ مدل زبانی بزرگ ۱۴

۲.۱.۲ معماری RAG ۱۵

۲.۲ نمایش برداری و پایگاه داده‌ی برداری ۱۵

۱.۲.۲ رمزگذار برداری ۱۵

۲.۲.۲ پایگاه داده‌ی برداری ۱۶

۳.۲ بازیابی کلیدواژه‌ای BM25 و ادغام رتبه ۱۶

۱.۳.۲ روش BM25 . . . . . ۱۶

۲.۳.۲ ادغام معکوس رتبه ۱۷

۳.۳.۲ رتبه‌بندی دوم ۱۷

۴.۲ مبانی فیزیکی داده‌های هدف ۱۸

۱.۴.۲ پارامترهای خطوط طیفی ۱۸
۲.۴.۲ ضریب شکست و پاشندگی ۱۸
۳.۴.۲ اپتیک غیرخطی مرتبه‌ی دوم و تطبیق فاز ۱۹
۴.۴.۲ بازده تبدیل، طول همدوسی و پهنای پذیرش ۲۰
۵.۴.۲ فروتبدیل پارامتری خودبه‌خودی ۲۱
۵.۲ پیشینه‌ی پژوهش ۲۲

۳ روش و طراحی سامانه ۲۳
۱.۳ معماری کلی ۲۳
۲.۳ مجموعه‌ی اسناد ۲۳
۱.۲.۳ مجموعه‌ی آزمایشی HITRAN ۲۳
۲.۲.۳ مجموعه‌ی بلورهای نوری ۲۴
۳.۳ تبدیل سند و بخش‌بندی ۲۵
۴.۳ نمایه در پایگاه داده‌های برداری ۲۶
۵.۳ بازیابی ۲۶
۱.۵.۳ بازیابی ترکیبی ۲۶
۲.۵.۳ گسترش نام ماده ۲۷
۳.۵.۳ پرسش فارسی ۲۷
۴.۵.۳ رتبه‌بندی دوم ۲۷
۵.۵.۳ نگهبان «پیدا نشد» ۲۷
۶.۳ تولید پاسخ و استخراج ساخت‌یافته ۲۸
۱.۶.۳ پاسخ با ارجاع ۲۸
۲.۶.۳ استخراج ساخت‌یافته ۲۸
۳.۶.۳ استخراج فرمول پاشندگی ۲۹
۷.۳ پایگاه داده‌ی فیزیکی آزموده ۲۹

۴ پیاده‌سازی ۳۱
۱.۴ ساختار نرم‌افزار ۳۱

۲.۴ زیرساخت ۳۲
۳.۴ رابط کاربری و ابزارها ۳۳
۴.۴ آزمون نرم‌افزار ۳۳

۵ ارزیابی و نتایج ۳۴
۱.۵ سنجه‌ها ۳۴
۲.۵ آزمون اولیه روی مجموعه‌های کوچک ۳۵
۱.۲.۵ RAG در برابر مدل بدون منبع ۳۵
۲.۲.۵ نمونه‌ی پاسخ‌ها ۳۶
۳.۲.۵ اثر پرسش فارسی ۳۶
۳.۵ ارزیابی جست‌وجو روی مجموعه‌ی بزرگ ۳۷
۱.۳.۵ روند در طول پروژه ۳۹
۴.۵ آزمایش‌های مقایسه‌ای ۳۹
۵.۵ درستی‌آزمایی فیزیکی ۴۰
۱.۵.۵ مثال حل‌شده: تولید هماهنگ دوم نوع اول در BBO ۴۱
۲.۵.۵ مثال حل‌شده: تطبیق فاز شبه‌فازی در PPLN ۴۴
۶.۵ استخراج خودکار فرمول: یک نتیجه‌ی منفی ۴۵
۷.۵ تحلیل خطا ۴۵

۶ بحث، محدودیت‌ها و نتیجه‌گیری ۴۷
۱.۶ پاسخ به پرسش‌های پژوهش ۴۷
۲.۶ محدودیت‌ها ۴۸
۳.۶ کارهای آینده ۴۹
۴.۶ نتیجه‌گیری ۴۹

آ واژه‌نامه ۵۱

ب منشأ عددهای گزارش ۵۲

پ اجرای سامانه ۵۳

منابع و مآخذ **۵۴**

چکیده‌ی انگلیسی **۵۷**

فهرست جداول

۱.۳ ترکیب مجموعه‌ی بلورهای نوری (شمارش مستقیم از پایگاه Qdrant، ۳ آبان ۱۴۰۵). . . . ۲۴

۲.۳ بررسی‌های خودکار روی هر مقدار استخراج‌شده. ۲۹

۳.۳ دارایی‌های پایگاه داده‌ی فیزیکی (۳ آبان ۱۴۰۵). ۳۰

۱.۴ بخش‌های نرم‌افزار. ۳۱

۲.۴ اجزای زیرساخت. ۳۲

۱.۵ بازیابی در مجموعه‌های آزمایشی. ۳۵

۲.۵ پاسخ به پرسش‌های آزمون HITRAN. ۳۵

۳.۵ نمونه‌ی پاسخ‌های ثبت‌شده در آزمون HITRAN. ۳۶

۴.۵ اثر پرسش فارسی بر بازیابی. ۳۷

۵.۵ ارزیابی ۲۰۰ پرسش طلایی روی سایت زنده. ۳۷

۶.۵ MRR@10 به تفکیک گروه پرسش (همان ارزیابی جدول ۵.۵). ۳۸

۷.۵ تغییرات مهم و اثر اندازه‌گیری‌شده‌ی آن‌ها. ۳۹

۸.۵ خروجی سامانه در برابر عدد گزارش‌شده در مقاله‌ی اصلی. ۴۰

۹.۵ خلاصه‌ی مثال حل‌شده‌ی SHG نوع اول در BBO در ۱/۰۶۴ میکرومتر. ۴۳

آ.۱ واژه‌نامه‌ی فارسی به انگلیسی اصطلاحات گزارش. ۵۱

فهرست تصاویر

۱.۳ معماری سامانه در سه مسیر نمایه‌سازی، پرسش و پاسخ، و داده و ابزار. ۲۴

۱.۵ MRR@10 به تفکیک گروه پرسش در ارزیابی ۲۰۰ پرسشی؛ ستون کم‌رنگ جست‌وجوی ترکیبی و ستون پررنگ با رتبه‌بندی دوم SubQ. عدد داخل پرانتز تعداد پرسش‌های هر گروه است. ۳۸

۲.۵ ضریب شکست عادی (n_o) و غیرعادی (n_e) بلور BBO از رابطه‌ی (۲.۵). خط‌چین‌های عمودی طول موج‌های ۰/۵۳۲ و ۱/۰۶۴ میکرومتر را نشان می‌دهند. دوشکستی منفی ($n_e < n_o$) شرط لازم تطبیق فاز نوع اول است. ۴۱

۳.۵ توان بهنجار هماهنگ دوم بر حسب انحراف از زاویه‌ی تطبیق فاز در بلور BBO به طول ۱ سانتی‌متر (SHG نوع اول در ۱/۰۶۴ میکرومتر)، محاسبه‌شده از رابطه‌های (۱۷.۲) و (۲.۵). خط‌چین افقی نصف بیشینه را نشان می‌دهد؛ پهنای کامل منحنی در این تراز حدود ۰/۵ میلی‌رادیان است. ۴۳

۴.۵ دوره‌ی تطبیق فاز شبه‌فازی مرتبه‌ی اول برای تولید هماهنگ دوم ۱/۰۶۴ میکرومتر در لیتیم نیوبات آلاییده با MgO، بر حسب دما، از رابطه‌ی (۵.۵) و فرمول Gayer و همکاران. . . . ۴۴

فصل ۱

مقدمه

۱.۱ بیان مسئله

طراحی یک آزمایش فیزیکی معمولاً با چند پرسش عددی ساده شروع می‌شود. ضریب شکست این بلور در طول موج ۱/۰۶۴ میکرومتر چقدر است؟ ضریب غیرخطی مؤثرش چند پیکومتر بر ولت است؟ با چه زاویه‌ای باید بریده شود تا تطبیق فاز رخ دهد؟ ضریب پهن‌شدگی فشاری یک خط جذبی CO_2 چقدر است؟ پاسخ این پرسش‌ها در ادبیات علمی وجود دارد، ولی پیدا کردنش دشوار است، به چهار دلیل:

- **پراکندگی:** فرمول سلمایر یک بلور در یک مقاله است، وابستگی دمایی‌اش در مقاله‌ای دیگر و ضرایب غیرخطی‌اش در مقاله‌ی سوم. برای یک بلور پرکاربرد ممکن است ده‌ها اندازه‌گیری مستقل با بازه‌های طول موجی و دمایی متفاوت وجود داشته باشد و انتخاب میان آن‌ها خود نیازمند خواندن دقیق هر مقاله است.

- **ناهمگونی:** قرارداد محورها، علامت ضرایب، واحدها و بازه‌ی اعتبار فرمول‌ها از مقاله‌ای به مقاله‌ی دیگر فرق می‌کند. برای نمونه، جابه‌جایی d_{31} و d_{32} در بلورهای KTP و LBO میان قراردادهای مختلف محور، خطایی رایج است. حتی واحد طول موج در فرمول پاشندگی (میکرومتر یا نانومتر) و تعریف ضریب غیرخطی (d یا $2d = \chi^{(2)}$) همیشه صریح نوشته نمی‌شود.

- **قالب سخت‌خوان:** عددها در جدول‌های چندستونه، معادله‌های تصویری و اسکن مقاله‌های دهه‌های ۱۹۶۰ تا ۱۹۹۰ هستند. این قالب‌ها برای خواننده‌ی انسانی قابل‌فهم‌اند، اما ابزارهای خودکار استخراج متن آن‌ها را به‌سادگی خراب می‌کنند.

- **هزینه‌ی بالای خطا:** یک عدد اشتباه می‌تواند به خرید بلور نامناسب یا هفته‌ها توقف کار آزمایشگاهی بینجامد. چون بلورهای غیرخطی با زاویه‌ی برش مشخص ساخته می‌شوند، خطای زاویه پس از ساخت قابل‌جبران نیست.

مدل‌های زبانی بزرگ (LLM) در نگاه نخست راه‌حل این مسئله به نظر می‌رسند، اما در سطح عدد و جدول قابل‌اتکا نیستند. این مدل‌ها پاسخ را از دانش ذخیره‌شده در پارامترهایشان می‌سازند. اگر عدد دقیقی را ندیده باشند یا آن را درست به خاطر نسپرده باشند، عددی باورپذیر ولی نادرست تولید می‌کنند. این پدیده «توهم» (hallucination) نام دارد [۱]. این مدل‌ها معمولاً منبع قابل‌بررسی هم نمی‌دهند، پس کاربر راهی برای تشخیص عدد درست از عدد ساختگی ندارد. در داده‌های فیزیکی کم‌تکرار، مانند ضریب پهن‌شدگی یک خط طیفی خاص یا ضریب ترمواپتیک یک بلور کم‌کاربرد، احتمال توهم بیشتر است، زیرا مدل این عدد را در داده‌های آموزشی خود به‌ندرت دیده است.

معماری «تولید تقویت‌شده با بازیابی» (Retrieval-Augmented Generation یا RAG) برای همین مسئله پیشنهاد شده است [۲]. در این معماری، پیش از پاسخ، بخش‌های مرتبط از یک مجموعه‌ی سند بازیابی می‌شوند و مدل فقط بر پایه‌ی همان بخش‌ها پاسخ می‌دهد. مسئله‌ی این پروژه، ساختن و سنجیدن چنین سامانه‌ای برای داده‌های فیزیکی است. در این حوزه، معیار موفقیت روانی پاسخ نیست، بلکه درستی عدد و دقت ارجاع آن به منبع است. به بیان دیگر، سامانه‌ای که پاسخ روان ولی بدون ارجاع می‌دهد برای کار فیزیکی ارزشی ندارد، ولی سامانه‌ای که فقط منبع درست را با شماره‌ی صفحه پیدا کند، حتی بدون نوشتن پاسخ، کار پژوهشگر را به‌طور محسوسی کوتاه می‌کند.

۲.۱ اهداف

هدف کلی پروژه ساختن زنجیره‌ای است که از مقاله‌ی PDF شروع شود و به عدد آزموده و قابل‌استفاده در محاسبه‌ی فیزیکی برسد. اهداف جزئی عبارت‌اند از:

۱. طراحی و پیاده‌سازی یک خط لوله‌ی کامل RAG برای مقاله‌های فیزیک: تبدیل PDF، بخش‌بندی، نمایه در پایگاه داده‌ی برداری، بازیابی و پاسخ.

۲. پاسخ به هر پرسش با ارجاع دقیق به مقاله، صفحه و محل روی صفحه، و پاسخ صریح «پیدا نشد» وقتی شاهدی در منابع نیست.

۳. استخراج ساخت‌یافته‌ی خواص فیزیکی (مقدار، واحد، شرایط اندازه‌گیری) همراه با بررسی‌های خودکار ضدتوهم.

۴. ارزیابی عینی سامانه با پایگاه‌های مرجع مستقل (HITRAN و refractiveindex.info) به‌جای برچسب‌گذاری دستی حجیم.

۵. پشتیبانی از پرسش فارسی برای دانشجویان و پژوهشگران فارسی‌زبان.

۶. وصل کردن داده‌ی آزموده به ابزارهای محاسبه‌ی فیزیکی (ضریب شکست، تطبیق فاز، تولید جفت فوتون) تا پاسخ پرسش‌های طراحی آزمایش کمّی و مستند باشد.

۳.۱ پرسش‌های پژوهش

چهار پرسش زیر مسیر طراحی و ارزیابی را تعیین کردند. هر پرسش به یک تصمیم مهندسی مشخص در سامانه وابسته است و پاسخ هر کدام در فصل ۶ با عددهای فصل ۵ داده می‌شود.

۱. آیا RAG در مقایسه با همان مدل زبانی بدون منبع، دقت پاسخ به پرسش‌های عددی فیزیک را بهتر می‌کند؟

۲. کدام روش بازیابی (برداری، کلیدواژه‌ای یا ترکیبی) برای متن‌های فیزیکی پر از نماد و فرمول بهتر کار می‌کند؟

۳. ترجمه‌ی ماشینی پرسش فارسی به انگلیسی چه اثری بر کیفیت بازیابی دارد؟

۴. آیا استخراج کاملاً خودکار ضرایب فرمول‌ها با مدل زبانی به دقت لازم برای کار فیزیکی می‌رسد؟

۴.۱ نوآوری و دامنه‌ی کار

ابزارهای موجود هر کدام بخشی از این مسئله را حل می‌کنند: refractiveindex.info داده‌ی ضریب شکست را با ارجاع دارد [۳]، نرم‌افزار SNLO محاسبه‌ی اپتیک غیرخطی را خوب انجام می‌دهد و دستیارهای پژوهشی مبتنی بر مدل زبانی روی متن مقاله‌ها کار می‌کنند. وجه متمایز این پروژه، زنجیره‌ی کامل از متن مقاله تا محاسبه است. هر عدد به صفحه و جدول مشخصی وصل است، پیش از ورود به پایگاه داده با عدد خود مقاله آزموده می‌شود و سپس در ابزار محاسبه به کار می‌رود. رابط فارسی با واژه‌نامه‌ی ثابت اصطلاحات فیزیک نیز بخشی از کار است.

دامنه‌ی کار دو مرحله داشت. مرحله‌ی نخست، آزمون مفهوم روی پارامترهای طیف‌سنجی گازهای جوّی (CO_2، CH_4 و H_2O) با مرجع HITRAN بود [۴]. این حوزه از آن رو انتخاب شد که پایگاه مرجع آن برای هر پارامتر، مقاله‌ی منبع را ذکر می‌کند و ارزیابی عینی را ممکن می‌سازد. مرحله‌ی دوم، ساخت سامانه‌ی کامل روی حوزه‌ی بلورهای اپتیک خطی و غیرخطی بود. هر دو مجموعه در کد پروژه به‌صورت «مجموعه»های (corpus) جداگانه نگه داشته می‌شوند تا افزودن یک حوزه‌ی تازه فقط به ساختن یک مجموعه‌ی جدید و فایل پیکربندی آن نیاز داشته باشد.

آنچه خارج از دامنه‌ی این پروژه است نیز باید روشن باشد: سامانه داده‌ی تجربی تازه تولید نمی‌کند، مدل زبانی تازه آموزش نمی‌دهد و جایگزین خواندن مقاله توسط پژوهشگر نیست. هدف، کوتاه کردن مسیر رسیدن به منبع درست و جلوگیری از ورود عدد آزموده‌نشده به محاسبه است.

۵.۱ ساختار گزارش

فصل ۲ مبانی نظری RAG، نمایش برداری، بازیابی کلیدواژه‌ای و مبانی فیزیکی داده‌های هدف را مرور می‌کند. فصل ۳ روش و معماری سامانه را شرح می‌دهد و فصل ۴ جزئیات پیاده‌سازی را. فصل ۵ نتایج ارزیابی را با عددهای اندازه‌گیری‌شده می‌آورد، از جمله نتیجه‌های منفی و دو مثال حل‌شده‌ی فیزیکی. فصل ۶ به بحث، محدودیت‌ها و کارهای آینده می‌پردازد. واژه‌نامه، منشأ عددهای گزارش و دستور اجرای سامانه در پیوست‌ها آمده‌اند.

فصل ۲

مبانی نظری و پیشینه

۱.۲ مدل‌های زبانی و معماری RAG

۱.۱.۲ مدل زبانی بزرگ

مدل زبانی بزرگ یک شبکه‌ی عصبی ترنسفورمر است [۵] که با پیش‌بینی واژه‌ی بعدی روی حجم بزرگی از متن آموزش دیده است. متن ورودی ابتدا به دنباله‌ای از «توکن»ها (واژه یا پاره‌واژه) شکسته می‌شود و هر توکن به یک بردار نگاشته می‌شود. هسته‌ی ترنسفورمر سازوکار «توجه» است که در آن هر توکن با همه‌ی توکن‌های دیگر دنباله مقایسه می‌شود:

$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V, \tag{۱.۲}$$

که در آن Q، K و V تصویرهای خطی بردارهای توکن‌ها و d_k بعد این تصویرهاست. مدل در هر گام توزیع احتمال توکن بعدی، $p(y_t \mid y_{<t}, x)$، را می‌سازد و پاسخ توکن به توکن تولید می‌شود.

دانش چنین مدلی در پارامترهایش «فشرده» شده است. این دانش پس از آموزش به‌روز نمی‌شود، منبع ندارد و برای عددهای کم‌تکرار ادبیات تخصصی دقیق نیست. دلیل آن روشن است: مدل برای کمینه کردن خطای پیش‌بینی واژه آموزش دیده است، نه برای به خاطر سپردن دقیق رقم‌ها. عددی که در کل داده‌ی آموزشی فقط چند بار آمده، احتمالاً به‌صورت تقریبی یا با عددی شبیه به آن جایگزین می‌شود. افزون بر این، طول ورودی مدل (پنجره‌ی متن) محدود است، پس نمی‌توان هزاران مقاله را یکجا به مدل داد.

۲.۱.۲ معماری RAG

در معماری RAG [۲، ۶] پاسخ در دو گام ساخته می‌شود. در گام بازیابی، برای پرسش q مجموعه‌ای از k بخش مرتبط $\{c_1, \dots, c_k\}$ از پایگاه اسناد پیدا می‌شود. در گام تولید، مدل زبانی پرسش و این بخش‌ها را با هم می‌بیند و پاسخ را فقط بر پایه‌ی آن‌ها می‌نویسد. در صورت‌بندی احتمالاتی Lewis و همکاران، بخش بازیابی‌شده یک متغیر پنهان است:

$$p(y \mid q) \approx \sum_{c \in \text{top-}k(q)} p_\eta(c \mid q)\, p_\theta(y \mid q, c), \tag{۲.۲}$$

که در آن p_η بازیاب و p_θ مدل تولیدکننده است. در پیاده‌سازی این پروژه، مانند بیشتر سامانه‌های عملی، به‌جای جمع وزن‌دار، همه‌ی k بخش برتر یکجا در متن ورودی مدل قرار می‌گیرند.

به این ترتیب سه ویژگی به دست می‌آید که برای کار علمی ضروری‌اند: پاسخ قابل‌ردیابی به منبع است، دانش با افزودن سند تازه به‌روز می‌شود و مدل می‌تواند در نبود شاهد بگوید «پیدا نشد». کیفیت پاسخ در این معماری بیش از هر چیز به کیفیت بازیابی وابسته است: اگر بخش درست در میان k بخش بازیابی‌شده نباشد، بهترین مدل زبانی هم پاسخ درست نمی‌دهد. به همین دلیل، بخش بزرگی از ارزیابی این پروژه بر کیفیت بازیابی متمرکز است.

۲.۲ نمایش برداری و پایگاه داده‌ی برداری

۱.۲.۲ رمزگذار برداری

در جست‌وجوی معنایی، هر بخش متن با یک مدل رمزگذار (embedding) به برداری در فضای d بعدی نگاشته می‌شود، به‌گونه‌ای که متن‌های هم‌معنا بردارهای نزدیک داشته باشند [۷، ۸]. در این پروژه از مدل bge-base-en-v1.5 استفاده شد [۹] که بردار ۷۶۸ بعدی تولید می‌کند. شباهت پرسش و بخش با شباهت کسینوسی سنجیده می‌شود:

$$\text{sim}(\mathbf{q}, \mathbf{c}) = \frac{\mathbf{q} \cdot \mathbf{c}}{\|\mathbf{q}\|\, \|\mathbf{c}\|}. \tag{۳.۲}$$

اگر بردارها از پیش بهنجار شوند ($\|\mathbf{q}\| = \|\mathbf{c}\| = 1$)، شباهت کسینوسی همان ضرب داخلی است و فاصله‌ی اقلیدسی هم با آن رابطه‌ی یکنوا دارد: $\|\mathbf{q} - \mathbf{c}\|^2 = 2 - 2\,\text{sim}(\mathbf{q}, \mathbf{c})$.

رمزگذارهایی مانند BGE با یادگیری تقابلی آموزش می‌بینند: برای هر پرسش، یک بخش مرتبط (نمونه‌ی مثبت) و تعدادی بخش نامرتبط (نمونه‌های منفی) در نظر گرفته می‌شود و تابع هزینه شباهت با نمونه‌ی مثبت را

نسبت به منفی‌ها بیشینه می‌کند [۸، ۹]:

$$\mathcal{L} = -\log \frac{\exp(\mathrm{sim}(\mathbf{q}, \mathbf{c}^+)/\tau)}{\exp(\mathrm{sim}(\mathbf{q}, \mathbf{c}^+)/\tau) + \sum_j \exp\big(\mathrm{sim}(\mathbf{q}, \mathbf{c}_j^-)/\tau\big)}, \tag{۴.۲}$$

که τ پارامتر دما است. چون این رمزگذار پرسش و بخش را جداگانه به بردار تبدیل می‌کند (معماری «دورمزگذاری» یا bi-encoder)، بردار همه‌ی بخش‌ها یک بار و از پیش محاسبه می‌شود و در زمان پرسش فقط بردار خود پرسش لازم است. همین ویژگی جست‌وجو در ده‌ها هزار بخش را در کسری از ثانیه ممکن می‌کند.

۲.۲.۲ پایگاه داده‌ی برداری

پایگاه داده‌ی برداری نرم‌افزاری است که این بردارها را همراه با متن و فراداده‌ی هر بخش ذخیره می‌کند و نزدیک‌ترین بردارها به بردار پرسش را سریع برمی‌گرداند. جست‌وجوی دقیق نیازمند مقایسه‌ی بردار پرسش با همه‌ی N بردار است و هزینه‌ی آن با Nd رشد می‌کند. برای میلیون‌ها بردار این روش کند است و از روش‌های تقریبی مانند گراف HNSW استفاده می‌شود [۱۰]. در HNSW بردارها رأس‌های یک گراف چندلایه‌اند: لایه‌های بالایی پیوندهای بلندبرد و تُنُک دارند و لایه‌ی پایین همه‌ی رأس‌ها را با پیوندهای کوتاه‌برد. جست‌وجو از لایه‌ی بالا شروع می‌شود و با حرکت حریصانه به سمت همسایه‌ی نزدیک‌تر، لایه به لایه پایین می‌آید. هزینه‌ی هر جست‌وجو تقریباً با $\log N$ رشد می‌کند و بهای آن، احتمال کوچکی برای از دست دادن نزدیک‌ترین همسایه‌ی واقعی است.

در این پروژه دو پایگاه برداری به کار رفت: ChromaDB برای اجرای محلی و آزمون‌ها، و Qdrant Cloud برای سایت. Qdrant امکان نگه داشتن بردار متراکم (معنایی) و بردار تنک (کلیدواژه‌ای) در کنار هم را دارد. بردار تنک برداری است با ابعاد برابر اندازه‌ی واژگان که فقط مؤلفه‌های مربوط به واژه‌های موجود در متن آن غیرصفرند.

۳.۲ بازیابی کلیدواژه‌ای BM25 و ادغام رتبه

۱.۳.۲ روش BM25

جست‌وجوی معنایی در یافتن مترادف‌ها قوی است، ولی نمادهای دقیق مانند γ_{air}، $R(50)$ یا فرمول شیمیایی $\mathrm{LiB_3O_5}$ را خوب تشخیص نمی‌دهد. دلیلش این است که رمزگذار برداری روی متن عمومی آموزش دیده و برای نمادهای کم‌تکرار نمایش دقیقی ندارد. روش کلاسیک BM25 [۱۱] به هر سند بر پایه‌ی تکرار واژه‌های پرسش در آن امتیاز می‌دهد:

$$\mathrm{BM25}(q, c) = \sum_{t \in q} \mathrm{IDF}(t)\, \frac{f(t, c)\,(k_1 + 1)}{f(t, c) + k_1 \left(1 - b + b\,\dfrac{|c|}{\overline{|c|}}\right)}. \tag{۵.۲}$$

در این رابطه $f(t,c)$ تعداد تکرار واژه‌ی t در بخش c، $|c|$ طول بخش، $\overline{|c|}$ میانگین طول بخش‌ها و k_1 و b پارامترهای تنظیم‌اند. وزن وارون فراوانی سند،

$$\mathrm{IDF}(t) = \ln\left(1 + \frac{N - n_t + 0.5}{n_t + 0.5}\right), \tag{۶.۲}$$

به واژه‌هایی که در تعداد کمی از N بخش آمده‌اند (n_t کوچک) وزن بیشتری می‌دهد. پس نماد کمیابی مانند $\mathrm{LiB_3O_5}$ وزن بسیار بیشتری از واژه‌ی رایجی مانند crystal می‌گیرد. پارامتر k_1 اشباع اثر تکرار را کنترل می‌کند (تکرار دهم یک واژه امتیاز کمتری از تکرار اول می‌افزاید) و b اثر طول بخش را بهنجار می‌کند.

۲.۳.۲ ادغام معکوس رتبه

برای ترکیب دو فهرست رتبه‌بندی‌شده، روش ادغام معکوس رتبه (Reciprocal Rank Fusion یا RRF) [۱۲] به کار رفت:

$$\mathrm{RRF}(c) = \sum_{r \in R} \frac{1}{k + \mathrm{rank}_r(c)}, \qquad k = 60, \tag{۷.۲}$$

که در آن R مجموعه‌ی فهرست‌های رتبه‌بندی (اینجا برداری و BM25) و $\mathrm{rank}_r(c)$ رتبه‌ی بخش c در فهرست r است. مزیت RRF این است که به مقیاس امتیازهای دو روش وابسته نیست و فقط از رتبه‌ها استفاده می‌کند. امتیاز شباهت کسینوسی در بازه‌ی صفر تا یک است، اما امتیاز BM25 حد بالایی ندارد و ترکیب مستقیم آن‌ها به بهنجارسازی دلخواه نیاز دارد. ثابت $k = 60$ اثر تفاوت رتبه‌های بالا را نرم می‌کند، به‌طوری که بخشی که در هر دو فهرست رتبه‌ی متوسطی دارد، می‌تواند از بخشی که فقط در یک فهرست اول است جلو بزند.

۳.۳.۲ رتبه‌بندی دوم

در رتبه‌بندی دوم، تعداد محدودی از نامزدهای اول (مثلاً ۳۰ بخش) با مدلی دقیق‌تر و کندتر دوباره مرتب می‌شوند [۱۳]. برخلاف رمزگذار دوگانه، رتبه‌بند «متقاطع» (cross-encoder) پرسش و بخش را با هم می‌خواند و برای هر جفت یک امتیاز مرتبط بودن می‌دهد. این کار دقیق‌تر است، چون مدل می‌تواند واژه‌های پرسش و بخش را مستقیماً با هم مقایسه کند، اما چون برای هر جفت یک اجرای کامل مدل لازم است، فقط روی تعداد کمی نامزد عملی است. یک مدل زبانی بزرگ هم می‌تواند نقش «داور» را بازی کند و برای هر بخش تعیین کند که آیا به پرسش پاسخ می‌دهد یا نه.

۴.۲ مبانی فیزیکی داده‌های هدف

۱.۴.۲ پارامترهای خطوط طیفی

هر خط جذبی مولکولی در پایگاه HITRAN با چند پارامتر توصیف می‌شود [۴]: مکان خط ν (بر حسب cm^{-1})، شدت خط S، ضریب پهن‌شدگی فشاری با هوا γ_{air} و پهن‌شدگی خودی γ_{self}، نمای وابستگی دمایی n_{air} و جابه‌جایی فشاری δ_{air}. نیم‌پهنای لورنتزی خط در فشار p و دمای T از این پارامترها ساخته می‌شود:

$$\gamma(p,T) = \left(\frac{T_{\mathrm{ref}}}{T}\right)^{n_{\mathrm{air}}} \Big[\gamma_{\mathrm{air}}\,(p - p_{\mathrm{self}}) + \gamma_{\mathrm{self}}\,p_{\mathrm{self}}\Big], \tag{۸.۲}$$

که $T_{\mathrm{ref}} = 296\ \mathrm{K}$ دمای مرجع HITRAN و p_{self} فشار جزئی خود گاز است. مکان خط نیز با فشار به‌اندازه‌ی $\delta_{\mathrm{air}}\,p$ جابه‌جا می‌شود. شکل خط با پروفایل Voigt مدل می‌شود که هم‌آمیخت پروفایل گاوسی پهن‌شدگی دوپلر و پروفایل لورنتزی پهن‌شدگی برخوردی است:

$$V(\nu) = \int_{-\infty}^{\infty} G(\nu';\alpha_D)\,L(\nu-\nu';\gamma)\,d\nu'. \tag{۹.۲}$$

در فشارهای جوّی نزدیک سطح زمین، سهم لورنتزی غالب است و دقت γ_{air} مستقیماً دقت مدل‌سازی جذب جوّی را تعیین می‌کند.

نکته‌ی کلیدی برای این پروژه آن است که HITRAN برای هر پارامتر، مقاله‌ی منبع را ذکر می‌کند. پس می‌توان پارامتر را با RAG از همان مقاله استخراج و با عدد HITRAN مقایسه کرد. این ویژگی یک «کلید پاسخ» مستقل و رایگان فراهم می‌کند.

۲.۴.۲ ضریب شکست و پاشندگی

وابستگی ضریب شکست به طول موج در ناحیه‌ی شفافیت معمولاً با فرمول تجربی سلمایر بیان می‌شود:

$$n^2(\lambda) = A + \sum_i \frac{B_i \lambda^2}{\lambda^2 - C_i}, \tag{۱۰.۲}$$

که در آن C_i به مربع طول موج‌های تشدید مربوط است. ریشه‌ی فیزیکی این فرمول مدل نوسانگر لورنتز است: هر جمله‌ی کسری سهم یک تشدید الکترونی (در فرابنفش) یا شبکه‌ای (در فروسرخ) را در قطبش‌پذیری محیط نشان می‌دهد. چون این فرمول برازش تجربی است، بیرون از بازه‌ی طول موجی که اندازه‌گیری روی آن انجام شده قابل‌اتکا نیست؛ این بازه بخشی ضروری از هر رکورد داده است.

پایگاه refractiveindex.info نه شکل مختلف فرمول پاشندگی (سلمایر، کوشی، چندجمله‌ای و جز آن) را تعریف می‌کند [۳] که همه در این پروژه پیاده‌سازی شدند. وابستگی دمایی ضریب شکست با ضریب ترمواپتیک dn/dT یا با ضرایب دمایی در خود فرمول بیان می‌شود. از روی $n(\lambda)$ ضریب گروهی و پاشندگی سرعت گروه (GVD) هم محاسبه می‌شوند:

$$n_g = n - \lambda \frac{dn}{d\lambda}, \qquad \beta_2 = \frac{\lambda^3}{2\pi c^2} \frac{d^2 n}{d\lambda^2}. \tag{۱۱.۲}$$

ضریب گروهی سرعت حرکت پوش تپ را تعیین می‌کند و β_2 پهن‌شدن زمانی تپ‌های کوتاه را؛ هر دو در طراحی تبدیل فرکانس با لیزرهای تپی اهمیت دارند.

در بلورهای ناهمسانگرد، ضریب شکست به جهت انتشار و قطبش نور بستگی دارد و با «بیضی‌گون ضریب شکست» توصیف می‌شود [۱۴]:

$$\frac{x^2}{n_x^2} + \frac{y^2}{n_y^2} + \frac{z^2}{n_z^2} = 1. \tag{۱۲.۲}$$

در بلور تک‌محوری دو ضریب اصلی برابرند ($n_x = n_y = n_o$، $n_z = n_e$) و در بلور دومحوری هر سه متفاوت‌اند. در بلور تک‌محوری، موج «عادی» با ضریب n_o مستقل از جهت انتشار منتشر می‌شود و موج «غیرعادی» ضریبی دارد که به زاویه‌ی θ میان بردار موج و محور نوری وابسته است. همین وابستگی زاویه‌ای ابزار اصلی تطبیق فاز دوشکستی است (بخش ۳.۴.۲). بنابراین، برای هر بلور ناهمسانگرد دست‌کم دو فرمول پاشندگی لازم است و نسبت دادن درست هر فرمول به محور درست، بخشی از کار ساختن پایگاه داده بود.

۳.۴.۲ اپتیک غیرخطی مرتبه‌ی دوم و تطبیق فاز

در محیط غیرمتقارن مرکزی، قطبش القایی جمله‌ی مرتبه‌ی دوم دارد [۱۵]:

$$P_i(\omega_3) = 2\varepsilon_0 \sum_{jk} d_{ijk}\, E_j(\omega_1)\, E_k(\omega_2). \tag{۱۳.۲}$$

تانسور d_{ij} (در نمادگذاری کوتاه‌شده، که جفت اندیس jk با یک اندیس از ۱ تا ۶ جایگزین می‌شود) به گروه نقطه‌ای بلور وابسته است. تقارن بلور بسیاری از مؤلفه‌ها را صفر یا با هم برابر می‌کند؛ برای نمونه، در گروه نقطه‌ای $3m$ (بلورهای BBO و لیتیم نیوبات) فقط چند مؤلفه‌ی مستقل باقی می‌ماند. ضریب مؤثر d_{eff} از تصویر تانسور روی بردارهای یکه‌ی قطبش سه موج به دست می‌آید:

$$d_{\text{eff}} = \sum_{ijk} e_{3i}\, d_{ijk}\, e_{1j}\, e_{2k}. \tag{۱۴.۲}$$

فرایندهایی مانند تولید هماهنگ دوم (SHG)، جمع و تفاضل فرکانس (SFG و DFG) و نوسانگر پارامتری (OPO) فقط وقتی کارآمدند که شرط تطبیق فاز برقرار باشد:

$$\Delta k = k_3 - k_1 - k_2 = \frac{2\pi n_3}{\lambda_3} - \frac{2\pi n_1}{\lambda_1} - \frac{2\pi n_2}{\lambda_2} = 0. \tag{۱۵.۲}$$

معنای فیزیکی این شرط پایستگی تکانه‌ی فوتون‌هاست: موج قطبش غیرخطی و موج تولیدشده باید هم‌گام حرکت کنند تا سهم لایه‌های پیاپی بلور به‌طور سازنده جمع شود. به دلیل پاشندگی عادی، در یک محیط همسانگرد معمولاً $n_3 > n_1, n_2$ است و این شرط خودبه‌خود برقرار نمی‌شود.

در بلور دوشکستی، این شرط با انتخاب زاویه‌ی انتشار (تطبیق فاز بحرانی) یا با تنظیم دما در زاویه‌ی ثابت (تطبیق فاز غیربحرانی، NCPM) برقرار می‌شود. در برهم‌کنش «نوع اول» دو موج ورودی قطبش یکسان دارند و در «نوع دوم» قطبش‌هایشان عمود بر هم است. در تطبیق فاز شبه‌فازی (QPM) [۱۶]، قطبش بلور به‌صورت دوره‌ای وارون می‌شود (مانند PPLN و PPKTP) و دوره‌ی لازم و ضریب مؤثر از رابطه‌ی زیر به دست می‌آیند:

$$\Lambda = \frac{2\pi}{|\Delta k|}, \qquad d_{\text{eff}}^{\text{QPM}} = \frac{2}{\pi}\,|d|. \tag{۱۶.۲}$$

ضریب $2/\pi$ از نخستین جمله‌ی سری فوریه‌ی تابع مربعی وارون‌شدن قطبش می‌آید. مزیت بزرگ QPM این است که می‌توان هر سه موج را با یک قطبش انتخاب کرد و از بزرگ‌ترین مؤلفه‌ی تانسور (مثلاً d_{33}) بهره برد، که در تطبیق فاز دوشکستی در دسترس نیست.

کمیت‌های عملی دیگر عبارت‌اند از جدایی مسیر انرژی (walk-off)، و پهنای پذیرش زاویه‌ای، طیفی و دمایی (بخش ۴.۴.۲). همه‌ی این محاسبه‌ها به $n(\lambda, T)$ دقیق وابسته‌اند. خطای 10^{-3} در ضریب شکست می‌تواند زاویه‌ی تطبیق فاز را به‌اندازه‌ی محسوسی جابه‌جا کند. به همین دلیل، داده‌ی ورودی باید با منبع آزموده شده باشد.

۴.۴.۲ بازده تبدیل، طول همدوسی و پهنای پذیرش

در تقریب موج تخت و دمش تهی‌نشده، شدت هماهنگ دوم پس از طول L از بلور از رابطه‌ی زیر پیروی می‌کند [۱۵]:

$$I_{2\omega} \propto \frac{d_{\text{eff}}^2\, L^2}{n_\omega^2\, n_{2\omega}\, \lambda_\omega^2}\; I_\omega^2\; \operatorname{sinc}^2\!\left(\frac{\Delta k L}{2}\right). \tag{۱۷.۲}$$

این رابطه سه نتیجه‌ی عملی دارد. نخست، بازده با d_{eff}^2 متناسب است. پس خطای ۱۰ درصدی در ضریب غیرخطی، خطای حدود ۲۰ درصدی در توان پیش‌بینی‌شده می‌دهد. دوم، اگر $\Delta k \neq 0$ باشد، توان هماهنگ دوم با طول بلور

به‌طور نوسانی تغییر می‌کند و بیشینه‌ی آن در «طول همدوسی» رخ می‌دهد:

$$L_c = \frac{\pi}{|\Delta k|}. \tag{۱۸.۲}$$

سوم، چون تابع sinc^2 در $|\Delta k L/2| \approx 1.39$ به نصف بیشینه می‌رسد، هر انحراف از شرایط تطبیق فاز (زاویه، طول موج یا دما) فقط تا حد معینی تحمل می‌شود. این حد «پهنای پذیرش» نام دارد و از مشتق Δk نسبت به آن متغیر به دست می‌آید. برای نمونه، پهنای پذیرش زاویه‌ای (پهنای کامل در نصف بیشینه) برابر است با:

$$\Delta\theta \cdot L \simeq \frac{2 \times 2.78}{|\partial \Delta k / \partial \theta|}. \tag{۱۹.۲}$$

پهنای پذیرش دمایی و طیفی هم به همین شکل از $\partial\Delta k/\partial T$ و $\partial\Delta k/\partial\lambda$ محاسبه می‌شوند. چون این مشتق‌ها مستقیماً از مشتق‌های $n(\lambda, T)$ ساخته می‌شوند، خطای کوچک در شیب فرمول پاشندگی، حتی اگر خود مقدار n درست باشد، پهنای پذیرش را جابه‌جا می‌کند. این روابط نشان می‌دهند که چرا یک فرمول پاشندگی نادرست یا یک مدل ترمواپتیک ناقص، مستقیماً به خطا در طراحی آزمایش منجر می‌شود. رابطه‌ی (۱۷.۲) برای باریکه‌ی کانونی‌شده باید با نظریه‌ی Boyd-Kleinman [۱۷] اصلاح شود که در این پروژه پیاده‌سازی نشده است (بخش ۲.۶). در فصل ۵ این روابط برای بلور BBO به‌طور عددی حل شده‌اند.

۵.۴.۲ فروتبدیل پارامتری خودبه‌خودی

در فروتبدیل پارامتری خودبه‌خودی (SPDC) یک فوتون دمش با بسامد ω_p در بلور غیرخطی به دو فوتون «علامت» و «بیکار» تبدیل می‌شود. پایستگی انرژی و تکانه می‌دهد:

$$\omega_p = \omega_s + \omega_i, \qquad \Delta k = k_p - k_s - k_i - \frac{2\pi}{\Lambda} \approx 0, \tag{۲۰.۲}$$

که جمله‌ی $2\pi/\Lambda$ فقط در بلورهای قطبیده‌ی دوره‌ای حضور دارد. حالت دوفوتونی با «دامنه‌ی طیفی مشترک» توصیف می‌شود که حاصل‌ضرب پوش طیفی دمش و تابع تطبیق فاز است [۱۸]:

$$f(\omega_s, \omega_i) = \alpha(\omega_s + \omega_i)\, \phi(\omega_s, \omega_i), \qquad \phi \propto \mathrm{sinc}\left(\frac{\Delta k L}{2}\right). \tag{۲۱.۲}$$

با تجزیه‌ی اشمیت این تابع، $f = \sum_j \sqrt{\lambda_j}\, u_j(\omega_s)\, v_j(\omega_i)$، عدد اشمیت $K = 1/\sum_j \lambda_j^2$ و خلوص طیفی تک‌فوتون $P = 1/K$ به دست می‌آیند. $K = 1$ یعنی دو فوتون از نظر طیفی هیچ همبستگی ندارند، که برای منابع تک‌فوتونِ اعلام‌شده مطلوب است. این کمیت‌ها نیز کاملاً به $n(\lambda, T)$ و دوره‌ی Λ وابسته‌اند.

۵.۲ پیشینه‌ی پژوهش

استخراج خودکار داده از متن علمی. ابزار ChemDataExtractor [۱۹] با قواعد زبانی و یادگیری ماشین، پایگاه‌های داده‌ای با ده‌ها هزار رکورد از خواص مواد ساخته است. این روش در مقیاس قوی است، اما برای فرمول‌های چندضریبی و جدول‌های پیچیده دقت محدودی دارد، زیرا قواعد آن برای الگوهای «نام ماده، خاصیت، مقدار» طراحی شده‌اند و نه برای مجموعه‌ای از ضرایب که فقط با هم معنا دارند.

پایگاه‌های مواد. Materials Project [۲۰] داده‌ی محاسباتی (DFT) برای بیش از صد هزار ماده دارد. refractiveindex.info [۳] مرجع آزاد ضریب شکست است و کتاب‌های دستی Dmitriev و همکاران [۲۱] و Nikogosyan [۲۲] مرجع کلاسیک بلورهای غیرخطی‌اند. این مراجع داده را گردآوری کرده‌اند، اما ارتباط مستقیمی با متن کامل مقاله‌ی منبع و ابزار محاسبه ندارند.

بازیابی متراکم و رتبه‌بندی. نشان داده شده است که رمزگذارهای دوگانه‌ی آموزش‌دیده با یادگیری تقابلی در پرسش و پاسخ با دامنه‌ی باز از BM25 بهتر عمل می‌کنند [۸]، و رتبه‌بند متقاطع مبتنی بر ترنسفورمر کیفیت رتبه‌ی اول را بهتر می‌کند [۱۳]. با این حال، این نتایج بیشتر روی متن عمومی (مانند ویکی‌پدیا) به دست آمده‌اند و برای متن علمی پر از نماد نیازمند آزمون مستقل‌اند؛ پرسش دوم این پژوهش از همین‌جا می‌آید.

دستیارهای پژوهشی مبتنی بر RAG. سامانه‌هایی مانند PaperQA2 [۲۳] با بازیابی و خواندن تکراری مقاله‌ها پاسخ مستند می‌نویسند و در برخی بنچمارک‌ها با متخصصان انسانی مقایسه شده‌اند. روش‌های ارزیابی RAG مانند RAGAS [۲۴] هم برای سنجش وفاداری پاسخ به منبع پیشنهاد شده‌اند.

کار حاضر در محل تلاقی این دسته‌ها است: بازیابی متن مقاله، داده‌ی عددی آزموده و ابزار محاسبه. هیچ‌کدام از این دسته‌ها به‌تنهایی این زنجیره را ندارد، ولی هر کدام در حوزه‌ی خودش از این پروژه قوی‌تر و جاافتاده‌تر است.

فصل ۳

روش و طراحی سامانه

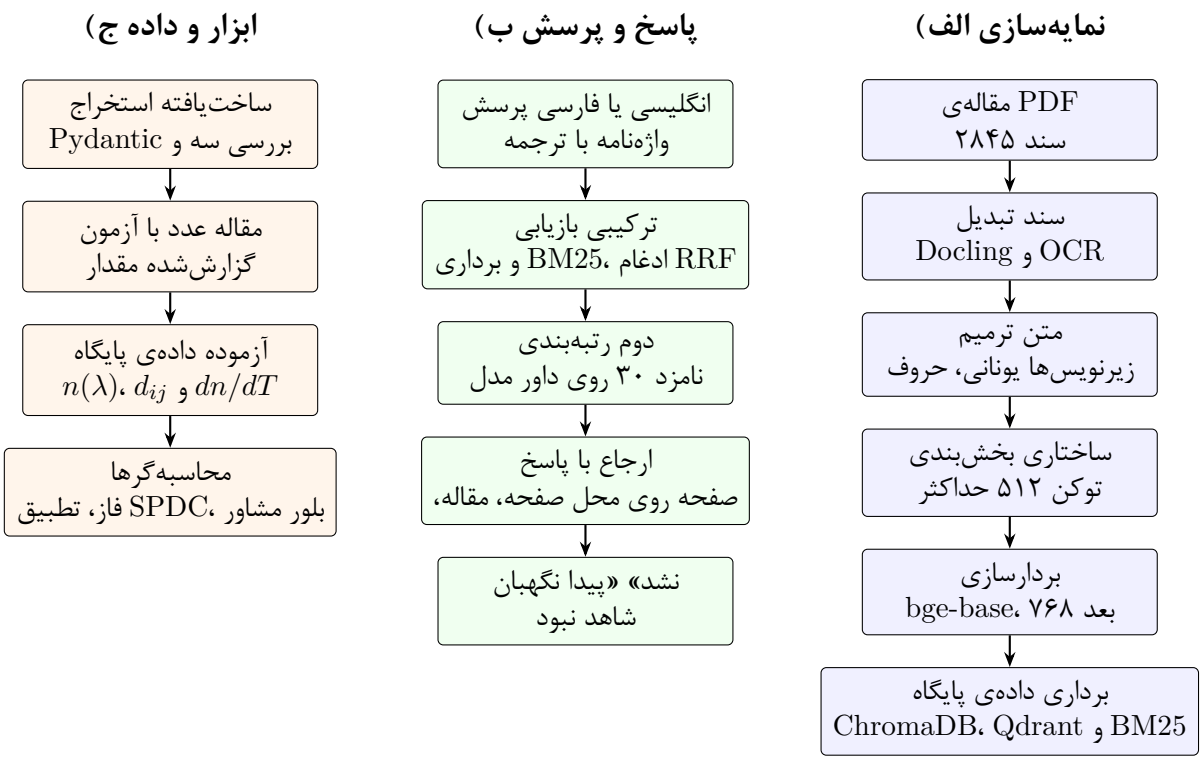
۱.۳ معماری کلی

سامانه سه لایه دارد. **لایه‌ی دانش** مقاله‌ها را به بخش‌های قابل‌جست‌وجو تبدیل و در پایگاه داده‌های برداری نمایه می‌کند. **لایه‌ی پرسش و استخراج** بخش‌های مرتبط را بازیابی می‌کند و پاسخ مستند یا رکورد ساخت‌یافته می‌سازد. **لایه‌ی داده و ابزار** عددهای آزموده را در پایگاه داده‌ی فیزیکی نگه می‌دارد و به محاسبه‌گرها می‌دهد. شکل ۱.۳ جریان داده را نشان می‌دهد. جدا بودن این سه لایه یک تصمیم طراحی آگاهانه بود: لایه‌ی دانش را می‌توان بدون تغییر لایه‌های دیگر با مجموعه‌ی تازه‌ای از مقاله‌ها پر کرد، و محاسبه‌گرها فقط از داده‌ی آزموده تغذیه می‌شوند، نه از خروجی مستقیم مدل زبانی.

۲.۳ مجموعه‌ی اسناد

۱.۲.۳ مجموعه‌ی آزمایشی HITRAN

ایده‌ی ارزیابی این مرحله از خود HITRAN گرفته شد. این پایگاه از مقاله‌ها گردآوری شده و برای هر پارامتر مقاله‌ی منبع را ذکر می‌کند. پس پارامترهای استخراج‌شده با RAG از همان مقاله‌ها را می‌توان با کتابخانه‌ی رسمی HAPI [۲۵] با عدد HITRAN مقایسه کرد، بدون نیاز به برچسب‌گذاری دستی گسترده. مجموعه‌ی آزمایشی شامل مقاله‌های دسترسی آزاد arXiv درباره‌ی پهن‌شدگی و شدت خطوط CO_2 و CH_4 بود و ۱۶ پرسش مرجع با صفحه‌ی پاسخ و مقدار درست برای آن نوشته شد. یکی از این پرسش‌ها عمداً بی‌جواب طراحی شد تا رفتار سامانه در نبود شاهد هم سنجیده شود.



شکل ۱.۳: معماری سامانه در سه مسیر نمایه‌سازی، پرسش و پاسخ، و داده و ابزار.

۲.۲.۳ مجموعه‌ی بلورهای نوری

مجموعه‌ی اصلی پروژه حوزه‌ی اپتیک خطی و غیرخطی است. فهرست اولیه از مقاله‌های منبع refractiveindex.info، کتاب‌های دستی اپتیک غیرخطی و جست‌وجوی هدفمند برای هر خانواده‌ی بلور ساخته شد. مشخصات مقاله‌ها (DOI، سال، نویسندگان، مجله و چکیده) از Crossref و OpenAlex گرفته شد. جدول ۱.۳ ترکیب مجموعه را نشان می‌دهد.

جدول ۱.۳: ترکیب مجموعه‌ی بلورهای نوری (شمارش مستقیم از پایگاه Qdrant، ۳ آبان ۱۴۰۵).

نوع سند	تعداد	سهم	بخش نمایه‌شده
متن کامل PDF	۲۲۱۴	۷۷/۸ درصد	۶۷۵۵۹ (۱۱۴۲۱ جدول)
فقط چکیده (PDF آزاد یا قانونی در دسترس نبود)	۵۹۸	۲۱/۰ درصد	۵۹۸
فقط مشخصات کتاب‌شناختی	۳۳	۱/۲ درصد	۳۳
جمع	۲۸۴۵	۱۰۰ درصد	۶۸۱۹۰

از ۲۷۲۸ مقاله‌ی مجله‌ای، ۱۳۳۳ مقاله (۴۸/۹ درصد) در مجله‌های چارک Q1 و ۹۳۸ مقاله (۳۴/۴ درصد) در چارک Q2 فهرست SCImago چاپ شده‌اند. بیشتر ۲۳۲ مقاله‌ای که در SCImago یافت نشدند، با نام قدیمی مجله‌های معتبر (مانند Physical Review B, Condensed Matter) ثبت شده‌اند. حدود ۱۷ درصد مجموعه

(۴۸۱ سند) پیش از ۱۹۹۰ منتشر شده است. این مقاله‌ها اغلب اسکن تصویری‌اند و به OCR نیاز دارند. وجود این مقاله‌های قدیمی اجتناب‌ناپذیر است، چون بسیاری از اندازه‌گیری‌های پایه‌ی ضریب شکست و ضرایب غیرخطی در همان دهه‌ها انجام شده‌اند و هنوز مرجع‌اند.

مجموعه در ۹ قفسه‌ی موضوعی مرتب شده است، از جمله بورات‌ها (۵۴۱ سند)، کالکوپیریت‌ها و کالکوژنیدهای فروسرخ میانی (۵۰۳)، نظریه و مدل‌های پاشندگی (۴۱۶) و نیوبات‌ها و تانتالات‌ها (۳۳۹).

یک تصمیم روش‌شناختی مهم این بود که داده‌ی refractiveindex.info **عمداً وارد جست‌وجو نشود**. این داده کلید ارزیابی است. اگر وارد نمایه می‌شد، سامانه پاسخ را از خود کلید پیدا می‌کرد و ارزیابی بی‌معنا می‌شد. این همان اصل جدا نگه داشتن داده‌ی آزمون از داده‌ی سامانه است که در هر ارزیابی تجربی رعایت می‌شود.

۳.۳ تبدیل سند و بخش‌بندی

PDFها با کتابخانه‌ی Docling [۲۶] به متن ساختاریافته تبدیل می‌شوند: عنوان بخش، پاراگراف، جدول با سطر و ستون، و کادر محدودکننده‌ی هر عنصر روی صفحه. قالب PDF برای نمایش طراحی شده است، نه برای استخراج متن: در آن فقط جای هر نویسه روی صفحه ثبت می‌شود و ترتیب خواندن، مرز ستون‌ها و ساختار جدول باید از روی چیدمان بازسازی شوند. چند مشکل ویژه‌ی متن فیزیکی در این مرحله حل شد:

- **حروف یونانی گمشده:** PDFهای ساخته‌شده با Word حروف یونانی را با فونت Symbol و در ناحیه‌ی Private Use یونیکد ذخیره می‌کنند (مثلاً ν به‌صورت U+F06E). این نویسه‌ها برای مدل زبانی و جست‌وجو نامرئی‌اند. با جدول استاندارد Adobe Symbol Encoding به یونیکد درست برگردانده شدند. اهمیت این ترمیم در متن طیف‌سنجی آشکار است، جایی که ν_3 و γ و δ نام کمیت‌های اصلی‌اند.
- **زیرنویس فرمول شیمیایی:** LiB_3O_5 که پس از استخراج به‌صورت «LiB 3 O 5» درمی‌آید، یکسان‌سازی شد تا جست‌وجوی کلیدواژه‌ای کار کند.
- **جدول‌ها:** هر جدول به شکل «سطر، ستون = مقدار» سریالایز می‌شود و سطر عنوان در هر قطعه تکرار می‌شود، تا هر عدد همراه با معنایش بازیابی شود. بدون این کار، قطعه‌ای از وسط یک جدول فقط فهرستی از عددهای بی‌نام بود.
- **معادله‌ها:** معادله‌های تصویری ۴۶ مقاله با مدل CodeFormula روی GPU به LaTeX تبدیل شدند.
- **OCR:** مقاله‌های اسکن‌شده با OCR دوباره خوانده شدند. هر مقاله فقط وقتی جایگزین شد که متنش بهتر شده بود و هیچ عددی از جدول‌هایش گم نشده بود (۴۵ مقاله از ۶۱ مقاله‌ی دور اول). کل کتاب Dmitriev و همکاران (۴۲۶ صفحه) هم OCR شد.

بخش‌بندی با HybridChunker کتابخانه‌ی Docling انجام می‌شود. این روش مرز بخش‌ها را بر پایه‌ی ساختار سند (بخش، پاراگراف، جدول) می‌گذارد و هر بخش را زیر سقف ۵۱۲ توکن مدل برداری نگه می‌دارد. انتخاب اندازه‌ی بخش یک مصالحه است: بخش کوچک دقیق‌تر بازیابی می‌شود ولی ممکن است بافت لازم برای فهم عدد (مثلاً شرایط اندازه‌گیری) را نداشته باشد، و بخش بزرگ بافت کامل‌تری دارد ولی بردارش میانگین چند موضوع است. سقف ۵۱۲ توکن از حداکثر طول ورودی مدل برداری می‌آید و مرزبندی ساختاری از شکستن پاراگراف‌ها در وسط جلوگیری می‌کند.

هر بخش این فراداده را دارد: شناسه‌ی سند، شماره‌ی صفحه، عنوان بخش، نوع (متن یا جدول) و مختصات روی صفحه. همین مختصات بعداً برای رنگی کردن محل منبع روی تصویر صفحه‌ی PDF به کار می‌رود، تا کاربر بتواند عدد را در خود مقاله ببیند.

۴.۳ نمایه در پایگاه داده‌های برداری

هر بخش با مدل bge-base-en-v1.5 به بردار ۷۶۸ بعدی تبدیل می‌شود. این مدل به این دلیل انتخاب شد که محلی و رایگان اجرا می‌شود (تکرارپذیری و صرفه‌جویی در سهمیه‌ی API) و در بنچمارک‌های بازیابی انگلیسی عملکرد خوبی دارد [۹]. در اجرای محلی، بردارها و متن در ChromaDB و یک docstore در LlamaIndex ذخیره می‌شوند و نمایه‌ی BM25 با کتابخانه‌ی bm25s ساخته می‌شود. برای سایت، **همان بردارهای ذخیره‌شده** به Qdrant Cloud منتقل شدند و در کنار هر بردار متراکم یک بردار تنک BM25 سمت سرور نگه داشته شد. یکسان بودن بردارها تضمین می‌کند که نتیجه‌ی ارزیابی محلی و سایت قابل‌مقایسه باشد. محاسبه‌ی دوباره‌ی بردارها با نسخه‌ی دیگری از مدل یا کتابخانه می‌توانست تفاوت‌های کوچکی ایجاد کند که مقایسه را مخدوش کند.

۵.۳ بازیابی

۱.۵.۳ بازیابی ترکیبی

برای هر پرسش، جست‌وجوی برداری و BM25 جداگانه اجرا و نتیجه‌ها با RRF (رابطه‌ی (۷.۲)) ادغام می‌شوند. در اجرای محلی ۸ بخش برتر به مدل زبانی داده می‌شود. انگیزه‌ی این طراحی، ماهیت دوگانه‌ی متن فیزیکی است: پرسش «پهن‌شدگی با بخار آب» به جست‌وجوی معنایی نیاز دارد، چون مقاله ممکن است عبارت H2O-broadening یا water-vapor broadened را به کار برده باشد، و پرسش درباره‌ی ν_3 یا $R(50)$ به تطابق دقیق نماد.

۲.۵.۳ گسترش نام ماده

نام کوتاه، نام کامل و نام فارسی بلور به فرمول شیمیایی نگاشته می‌شود. برای نمونه «BBO» و «باریم بورات» هر دو به BaB_2O_4 نگاشته می‌شوند. یک جدول واحد نام‌ها برای جست‌وجو و محاسبه‌گرها استفاده می‌شود. در این جدول، طولانی‌ترین نام اول تطبیق داده می‌شود تا «cesium lithium borate» با LBO یا «alpha-BBO» با BBO اشتباه نشود. فرمول‌ها با حروف بزرگ و کوچک خودشان تطبیق داده می‌شوند تا «gap» با GaP یکی نشود. اگر پرسش نام ماده داشته باشد، یک جست‌وجوی جداگانه روی همان ماده هم اجرا می‌شود. این جست‌وجوی جداگانه برای پرسش‌هایی لازم است که بیشتر واژه‌هایشان عمومی‌اند (مانند «ضریب شکست») و نام ماده فقط یک واژه از آن‌هاست.

۳.۵.۳ پرسش فارسی

مقاله‌ها انگلیسی‌اند و مدل برداری هم انگلیسی است. پس پرسش فارسی اول با یک مدل زبانی به انگلیسی ترجمه می‌شود. ترجمه‌ی تحت‌اللفظی اصطلاحات فیزیک اغلب غلط است. برای نمونه «عدد موج» wavenumber است و نه wavelength، و «غیرعادی» در اپتیک بلور extraordinary است و نه abnormal. برای همین یک واژه‌نامه‌ی ثابت فیزیکی به مدل ترجمه داده می‌شود. در اجرای محلی ترجمه با همان مدل محلی (Qwen3-4B) و در سایت با Llama 3.3 70B روی Workers AI انجام می‌شود. ترجمه و بردار پرسش‌ها در حافظه‌ی نهان نگه داشته می‌شوند تا پرسش تکراری هزینه‌ی دوباره نداشته باشد.

۴.۵.۳ رتبه‌بندی دوم

در سایت، ۳۰ نامزد اول می‌توانند با یک مدل داور (SubQ) دوباره مرتب شوند. این مدل برای هر بخش تشخیص می‌دهد که آیا بخش به پرسش پاسخ می‌دهد یا نه. رتبه‌بند متقاطع bge-reranker-base هم آزموده شد (بخش ۴.۵).

۵.۵.۳ نگهبان «پیدا نشد»

اگر نام ماده یا واژه‌های اصلی پرسش در هیچ نتیجه‌ای نباشد، یا شباهت برداری بهترین نتیجه از یک آستانه کمتر باشد، سامانه صریحاً می‌گوید منبعی پیدا نشد. این نگهبان در برابر خطای رایج سامانه‌های بازیابی طراحی شده است: جست‌وجوی برداری همیشه نزدیک‌ترین بردارها را برمی‌گرداند، حتی اگر هیچ‌کدام واقعاً مرتبط نباشند.

۶.۳ تولید پاسخ و استخراج ساخت‌یافته

۱.۶.۳ پاسخ با ارجاع

مدل زبانی (Qwen3-4B محلی از راه Ollama [۲۷]، یا Gemini) پرسش و بخش‌های بازیابی‌شده را می‌بیند. دستور مدل این است که فقط از همین بخش‌ها پاسخ دهد، برای هر عدد منبع را به شکل «نویسنده (سال)، صفحه» بیاورد و اگر شاهدی نیست بگوید «پیدا نشد». برای مقایسه، همان مدل بدون منبع هم پاسخ می‌دهد. خروجی دیگری به نام «بسته‌ی منابع» هم ساخته می‌شود: فایلی شامل پرسش و بخش‌های منبع که می‌توان آن را در هر چت هوش مصنوعی بارگذاری کرد، بدون مصرف API.

قواعد اصلی دستور (prompt) مدل، که عیناً در کد پروژه به کار رفته‌اند، چنین‌اند:

۱. فقط از منابع شماره‌دار داده‌شده پاسخ بده و هر جمله را با شماره‌ی منبعش ارجاع بده.

۲. مقادیر عددی را دقیقاً همان‌طور که نوشته شده‌اند، همراه با واحد، عدم‌قطعیت و شرایط اندازه‌گیری (دما، فشار، گاز پهن‌کننده، باند طیفی) گزارش کن.

۳. اگر منبع مقدار تجربی را از مقدار نظری یا محاسبه‌شده جدا کرده، این تمایز را حفظ کن.

۴. اگر منابع پاسخ را ندارند، دقیقاً بنویس: «Not found in the provided sources».

۵. ارجاع را با شماره‌ی صفحه بنویس، مانند (Source 2, p. 5)، و پاسخ را به فارسی بنویس، ولی نمادها، واحدها و اعداد را همان‌طور که در منبع آمده نگه دار.

قاعده‌ی دوم برای داده‌ی فیزیکی اهمیت ویژه دارد. مقدار «0.0712(3)» بدون عدم‌قطعیت، یا ضریب پهن‌شدگی بدون نام گاز پهن‌کننده، از نظر فیزیکی ناقص است. قاعده‌ی سوم هم از آن رو لازم است که بسیاری از مقاله‌های طیف‌سنجی مقدار اندازه‌گیری‌شده را کنار مقدار محاسبه‌شده‌ی نظری در یک جدول می‌آورند و جابه‌جایی این دو خطایی جدی است.

۲.۶.۳ استخراج ساخت‌یافته

برای استخراج خواص، مدل زبانی یک قالب داده‌ی Pydantic را پر می‌کند. فیلدهای اصلی این قالب عبارت‌اند از: ماده، ایزوتوپولوگ، نام خاصیت، مقدار به همان شکلی که نوشته شده، مقدار عددی، عدم‌قطعیت، واحد، موقعیت طیفی، دما، فشار، گاز پهن‌کننده، روش (تجربی، نظری یا گردآوری‌شده) و یک نقل‌قول عینی از متن به‌عنوان شاهد. نگه داشتن «مقدار به همان شکلی که نوشته شده» در کنار مقدار عددی، امکان بررسی بعدی را فراهم می‌کند. سپس خط لوله شناسه‌ی سند، بخش و صفحه را اضافه می‌کند و سه بررسی خودکار انجام می‌دهد (جدول ۲.۳).

جدول ۲.۳: بررسی‌های خودکار روی هر مقدار استخراج‌شده.

بررسی	پرسش	خطایی که می‌گیرد
value_in_source	آیا عدد، همان‌طور که نوشته شده، در متن بخش منبع هست؟	عددسازی مدل
evidence_verified	آیا جمله‌ی شاهد عیناً در متن منبع هست؟	شاهد ساختگی
plausible	آیا مقدار در بازه‌ی فیزیکی معقول آن خاصیت است؟	خطای واحد، برداشت اشتباه (مثلاً «تعداد خط‌ها» به‌جای ضریب)

بازه‌های فیزیکی برای هر مجموعه در یک فایل پیکربندی تعریف شده‌اند. برای نمونه، ضریب شکست باید در بازه‌ی $1 < n < 5$ باشد. این بررسی‌ها مکمل یکدیگرند: بررسی اول جلوی عددی را می‌گیرد که در منبع نیست، بررسی دوم جلوی شاهد ساختگی را، و بررسی سوم عددی را که در منبع هست ولی به خاصیت دیگری تعلق دارد.

۳.۶.۳ استخراج فرمول پاشندگی

بسیاری از مقاله‌های اپتیکی ضریب شکست را فقط به شکل نمودار نشان می‌دهند، اما ضرایب فرمول برازش‌شده را در جدول یا متن می‌آورند. سامانه این ضرایب را استخراج می‌کند و با آن‌ها $n(\lambda)$ را در هر طول موجی حساب می‌کند. هر فرمول استخراج‌شده سه بررسی دارد: همه‌ی ضرایب در متن منبع هستند؟ فرمول از نظر فیزیکی معقول است ($1 < n < 5$، بدون تشدید در بازه و با $|dn/d\lambda|$ کوچک)؟ و اختلافش با مدخل همان مقاله در refractiveindex.info چقدر است؟

۷.۳ پایگاه داده‌ی فیزیکی آزموده

نتیجه‌ی بخش ۶.۵ نشان داد که استخراج کاملاً خودکار ضرایب به دقت لازم نمی‌رسد. پس برای داده‌ای که به محاسبه‌گرها وارد می‌شود، روش نیمه‌دستی انتخاب شد. سامانه بخش منبع را پیدا می‌کند، عدد خوانده و ثبت می‌شود و سپس با یک «آزمون» درستی‌آزمایی می‌شود. قاعده‌ی کلیدی این است: **هیچ عددی بدون آزمون با عدد خود مقاله وارد پایگاه نمی‌شود.** هر رکورد شناسه‌ی سند، شماره‌ی صفحه و جای دقیق داده (مثلاً «جدول ۲، ستون سوم») را دارد. هر فرمول هم یک مقدار گزارش‌شده در خود مقاله همراه دارد، مانند زاویه‌ی تطبیق فاز، ضریب شکست در یک طول موج یا دوره‌ی QPM. آزمون خودکار بررسی می‌کند که محاسبه با ضرایب ثبت‌شده همان عدد را بازتولید کند. این روش خطای خواندن ضرایب را می‌گیرد، چون یک ضریب نادرست تقریباً همیشه عدد گزارش‌شده را تغییر می‌دهد. جدول ۳.۳ دارایی‌های پایگاه را نشان می‌دهد.

برای نمونه، رکورد بلور BBO در فایل `nonlinear_coefficients.yml` به این شکل است:

جدول ۳.۳: دارایی‌های پایگاه داده‌ی فیزیکی (۳ آبان ۱۴۰۵).

داده	پوشش	منبع
منحنی ضریب شکست	۲۳۳۰ ماده	refractiveindex.info (مجوز CC0) به‌اضافه‌ی ۹۷ فرمول برای ۸۴ ماده که مستقیماً از مقاله‌های مجموعه خوانده شد
تانسور غیرخطی d_{ij}	۱۰۵ بلور	Roberts 1992 [۲۸]، کتاب‌های Dmitriev [۲۱] و Nikogosyan [۲۲] و اندازه‌گیری‌های مستقیم
مدل ترمواپتیک	۶۷ بلور (۷۹ مدل)	فرمول‌های دمایی Kato و همکاران، Ghosh و اندازه‌گیری‌های مستقیم
بلور ناهمسانگرد در محاسبه‌گر	۱۸۶ بلور	هر بلوری که فرمول دو یا سه محور دارد
کارت مشخصات عملی (شفافیت، رطوبت‌گیری، آستانه‌ی آسیب)	۵۸ بلور	Nikogosyan 2005 و مقاله‌های مجموعه

```
- material: BaB2O4
  point_group: 3m
  d: {22: 2.2, 21: -2.2, 16: -2.2, 31: 0.1, 32: 0.1, 15: 0.1, 24: 0.1}
  sources:
    - {doc_id: 10.1109_3.55534, cite: "Eckardt et al. (1990)", pdf_page: 10,
      what: "|d22| = 2.2 pm/V (Table III), from the measured d_eff = 1.94 pm/V
      of type-I SHG at 1.064 um"}
    - {doc_id: 10.1109_3.159516, cite: "Roberts (1992)", pdf_page: 13,
      what: "d31 = 0.1 pm/V and the relative sign d21 = -d22 (Table VI)"}
  notes: "3m: d21 = d16 = -d22, d31 = d32 = d15 = d24"
```

این رکورد سه ویژگی طراحی پایگاه را نشان می‌دهد. نخست، همه‌ی مؤلفه‌های غیرصفر تانسور نوشته شده‌اند و مؤلفه‌هایی که تقارن گروه نقطه‌ای $3m$ با هم برابر می‌کند، در یادداشت مشخص شده‌اند. دوم، هر عدد به شناسه‌ی سند (DOI)، شماره‌ی صفحه‌ی PDF و جدول مشخصی ارجاع دارد. سوم، علامت نسبی مؤلفه‌ها از منبع جداگانه‌ای (Roberts 1992) آمده و این منبع هم ثبت شده است. سایت d_{eff} را مستقیماً از جمع $\sum e_{3i} d_{ijk} e_{1j} e_{2k}$ (رابطه‌ی (۱۴.۲)) روی بردارهای میدان سه موج محاسبه می‌کند، پس نیازی به انتخاب دستی فرمول d_{eff} برای هر گروه نقطه‌ای نیست. این روش احتمال خطای نقل فرمول‌های d_{eff} از جدول‌های کتاب‌ها را هم حذف می‌کند. قاب محورهای بلورهای دومحوری (که در ادبیات گاهی جابه‌جا آمده است) با مقادیر اندازه‌گیری‌شده‌ی d_{eff} در مقاله‌های مجموعه تثبیت شده و آزمون‌های خودکار آن را دوباره محاسبه می‌کنند.

فصل ۴

پیاده‌سازی

۱.۴ ساختار نرم‌افزار

کد پروژه در یک مخزن Git نگه داشته می‌شود (github.com/aminsadidi/RAG) و از ۵ مهر ۱۴۰۵ تا زمان نگارش این گزارش ۲۹۷ نسخه‌ی ثبت‌شده (commit) دارد. نرم‌افزار چهار بخش اصلی دارد که در جدول ۱.۴ آمده‌اند.

جدول ۱.۴: بخش‌های نرم‌افزار.

بخش	زبان و محل اجرا	کارکرد
src/matrag/	Python؛ Google Colab یا رایانه‌ی محلی	خط لوله‌ی داده: تبدیل، بخش‌بندی، بردارسازی، نمایه، بازیابی، پاسخ، استخراج، موتور فرمول و ارزیابی
notebooks/	Google Colab	اجرای همان خط لوله روی مجموعه‌ی Google Drive؛ چند نوت‌بوک کارگر برای تبدیل موازی
web/	JavaScript؛ Cloudflare Workers	سایت: جست‌وجو در Qdrant، نمایش صفحه‌ی PDF و محاسبه‌گرهایی که در مرورگر اجرا می‌شوند
research_package/	Python	نسخه‌ی مرجع محاسبه‌های تطبیق فاز و SPDC برای آزمودن نسخه‌ی JavaScript

ماژول‌های اصلی پایتون عبارت‌اند از: ingest.py (تبدیل و بخش‌بندی)، textfix.py (ترمیم نویسه‌ها)، index.py و qdrant_store.py (نمایه)، retrieve.py (بازیابی ترکیبی)، qa.py (پاسخ، ترجمه و واژه‌نامه)، extract.py و schema.py (استخراج ساخت‌یافته)، dispersion.py و formulas.py (موتور فرمول پاشندگی)، crystal_names.py (جدول نام بلورها) و evaluate.py (ارزیابی). ابزار خط فرمان matrag همه‌ی این مراحل را با زیرفرمان‌هایی مانند ingest، retrieval evaluate و reference hitran در دسترس می‌گذارد. هر ماژول یک وظیفه‌ی مشخص دارد و از راه ساختارهای داده‌ی ساده (فهرست

بخش‌ها با فراداده) با ماژول بعدی ارتباط می‌گیرد، پس هر مرحله را می‌توان جداگانه آزمود یا جایگزین کرد.

فیزیک محاسبه‌گرها عمداً دو بار نوشته شده است. سایت باید بدون سرور و در مرورگر حساب کند (JavaScript)، و نسخه‌ی پایتون با آزمون‌هایش مرجعی است که عددهای سایت با آن مقایسه می‌شوند. موتور فرمول پاشندگی JavaScript با موتور پایتون روی ۶۸۶۷ نقطه مقایسه شد و خروجی‌ها یکسان بودند. این دوبار نوشتن، اگرچه کار بیشتری می‌طلبد، روشی استاندارد برای یافتن خطاهای پیاده‌سازی است: احتمال اینکه دو پیاده‌سازی مستقل خطای یکسانی داشته باشند کم است.

۲.۴ زیرساخت

جدول ۲.۴ اجزای زیرساخت را نشان می‌دهد. انتخاب‌ها با دو قید انجام شدند: هزینه‌ی صفر یا نزدیک به صفر برای یک پروژه‌ی دانشجویی، و امکان تکرار نتایج.

جدول ۲.۴: اجزای زیرساخت.

جزء	فناوری	نقش
پردازش سنگین	Google Colab (GPU T4) و GitHub Actions	تبدیل PDF، OCR با ۲۰ اجراکننده‌ی موازی، نمایه‌سازی
ذخیره‌ی PDF	Google Drive	آرشیو اصلی و حافظه‌ی نهان تبدیل‌ها؛ تبدیل در قطعه‌های ۴۰ صفحه‌ای
پایگاه برداری محلی	ChromaDB و LlamaIndex	اجرای محلی، آزمون‌ها و ارزیابی
پایگاه برداری سایت	Qdrant Cloud	۶۸۱۹۰ بخش با بردار متراکم و BM25؛ ادغام RRF در خود Qdrant
سایت و API	Cloudflare Workers	جست‌وجو، محاسبه‌گرها، احراز هویت، نمایش PDF با pdf.js
مدل‌های زبانی	Ollama (Qwen3-4B)، Gemini، Workers AI	پاسخ و استخراج (محلی)، ترجمه‌ی پرسش فارسی و بردار پرسش (سایت)

تبدیل PDF در قطعه‌های ۴۰ صفحه‌ای انجام می‌شود تا قطع شدن نشست Colab کار انجام‌شده را از بین نبرد؛ خروجی هر قطعه در حافظه‌ی نهان Google Drive ذخیره می‌شود و اجرای بعدی از همان‌جا ادامه می‌یابد. متن مقاله‌ها حق نشر دارد. برای همین فایل‌های PDF هرگز در مخزن کد قرار نمی‌گیرند و سایت عمومی نیست. سایت سطوح دسترسی جداگانه دارد، از جمله حالتی که فقط ابزارهای محاسبه را بدون نمایش PDF در اختیار می‌گذارد.

۳.۴ رابط کاربری و ابزارها

دو رابط ساخته شد. رابط محلی با Gradio این زبانه‌ها را دارد: افزودن مقاله، پرسش و پاسخ (با پاسخ مدل بدون منبع در کنارش و نمایش صفحه‌ی مقاله با بخش استفاده‌شده‌ی رنگی)، بسته‌ی منابع، استخراج خواص، فرمول به جدول ضریب شکست، و رسم طیف جذبی HITRAN با HAPI. در زبانه‌ی آخر، طیف دوم با مقدارهای استخراج‌شده از مقاله رسم و اختلاف دو طیف نشان داده می‌شود. این مقایسه‌ی دیداری، اثر فیزیکی یک خطای استخراج را مستقیماً نشان می‌دهد.

سایت (`matrag.ethanjamescarter1995.workers.dev`) دوزبانه است و این ابزارها را دارد:

- **جست‌وجو:** پرسش فارسی یا انگلیسی؛ نتایج گروه‌بندی‌شده به تفکیک مقاله با نام، سال، صفحه و DOI؛ کادر زرد روی صفحه‌ی اصلی PDF؛ پاسخ «پیدا نشد». سایت خودش پاسخ نوشتاری تولید نمی‌کند و بسته‌ی منابع را برای مدل‌های زبانی بیرونی آماده می‌کند.
- **ضریب شکست:** منحنی $n(\lambda)$، ضریب گروهی و GVD برای ۲۳۳۰ ماده، با مقایسه‌ی منابع.
- **تطبیق فاز:** فرایندهای SHG، SFG، DFG و OPO در ۱۸۶ بلور؛ حل معادله‌ی فرنل برای بلور دومحوری؛ walk-off؛ پهنای پذیرش؛ d_{eff}؛ دمای NCPM؛ و پیکربندی‌های QPM.
- **SPDC:** دامنه و شدت طیفی مشترک، خلوص، عدد اشمیت و فرورفتگی HOM؛ دمش گاوسی کانونی‌شده (Bennink 2010 [۱۸]).
- **مشاور انتخاب بلور:** کاربر شرایط ثابت آزمایشگاه (فرایند، طول موج‌ها، بازه‌ی دمای آون، طول بلور، حداکثر walk-off و جز آن) را وارد می‌کند و سامانه همه‌ی ۱۸۶ بلور را می‌سنجد. خروجی فهرست بلورهای مناسب با رتبه و دلیل رد شدن هر بلور دیگر است (۱۶ دلیل تعریف‌شده، مانند جذب در یکی از طول موج‌ها، دمای خارج از بازه‌ی آون یا صفر بودن d_{eff}).

۴.۴ آزمون نرم‌افزار

تا ۳ آبان ۱۴۰۵، ۲۳۷ آزمون خودکار پایتون و ۸۲ آزمون سمت سایت نوشته شده بود. این آزمون‌ها چهار دسته‌اند: درستی فیزیک (زاویه، دما، دوره‌ی QPM و d_{eff} در برابر عدد مقاله)، ساختار داده‌ها، کامل بودن ترجمه‌ی انگلیسی رابط، و رفتار API در برابر ورودی خراب. آزمون‌های پایتون بدون اینترنت و بدون مدل زبانی اجرا می‌شوند، پس نتیجه‌شان به در دسترس بودن سرویس‌های بیرونی یا رفتار غیرقطعی مدل‌ها وابسته نیست. چند دور اشکال‌یابی روی سایت هم انجام شد و هر اشکال پیداشده یک آزمون تازه به مجموعه اضافه کرد، تا همان اشکال دوباره بازنگردد.

فصل ۵

ارزیابی و نتایج

۱.۵ سنجه‌ها

کیفیت بازیابی با «پرسش‌های طلایی» سنجیده شد. برای هر پرسش، مقاله‌ی درست (و در مجموعه‌ی آزمایشی، صفحه‌ی درست) از پیش مشخص است. دو سنجه به کار رفت:

$$\mathrm{R@}k = \frac{1}{|Q|}\sum_{q\in Q} \mathbb{1}\left[\mathrm{rank}_q \le k\right], \qquad \mathrm{MRR@10} = \frac{1}{|Q|}\sum_{q\in Q} \frac{\mathbb{1}\left[\mathrm{rank}_q \le 10\right]}{\mathrm{rank}_q}, \tag{۱.۵}$$

که در آن rank_q رتبه‌ی نخستین نتیجه‌ی درست برای پرسش q و $\mathbb{1}[\cdot]$ تابع نشانگر است. سنجه‌ی $\mathrm{R@}k$ می‌گوید در چه سهمی از پرسش‌ها پاسخ درست در k نتیجه‌ی اول هست، و MRR به رتبه‌ی دقیق آن هم حساس است: پاسخ درست در رتبه‌ی اول امتیاز ۱، در رتبه‌ی دوم امتیاز نیم و در رتبه‌ی دهم امتیاز یک‌دهم می‌گیرد. MRR برابر ۱ یعنی پاسخ درست همیشه نتیجه‌ی اول است. برای پاسخ‌ها، «دقت» سهم پرسش‌هایی است که پاسخ مقدار درست را دارد. «امتناع درست» هم سهم پرسش‌های بی‌جوابی است که سامانه برایشان «پیدا نشد» گفته است.

برای سنجیدن عدم‌قطعیت آماری، بازه‌ی اطمینان با بازنمونه‌گیری bootstrap [۲۹] محاسبه شد: از مجموعه‌ی $|Q|$ پرسش، $|Q|$ پرسش با جایگذاری برداشته و سنجه دوباره حساب می‌شود؛ پس از ۵۰۰۰ تکرار، صدک‌های ۲/۵ و ۹۷/۵ توزیع حاصل، بازه‌ی اطمینان ۹۵ درصد را می‌دهند. برای مقایسه‌ی دو روش، بازنمونه‌گیری «جفتی» روی همان پرسش‌ها انجام می‌شود، تا تفاوت دشواری پرسش‌ها در هر دو روش یکسان اثر کند.

۲.۵ آزمون اولیه روی مجموعه‌های کوچک

نخستین ارزیابی روی دو مجموعه‌ی کوچک (سه مقاله در هر حوزه) انجام شد تا درستی خط لوله و ابزارهای ارزیابی سنجیده شود. معیار برخورد در این آزمون سخت‌گیرانه بود: صفحه‌ی درست از مقاله‌ی درست در k بخش اول. جدول ۱.۵ نتیجه را نشان می‌دهد.

جدول ۱.۵: بازیابی در مجموعه‌های آزمایشی (`results/eval/*_retrieval.csv`).

حوزه	روش	R@1	R@3	R@5	MRR
HITRAN (۱۵ پرسش)	برداری	۰/۶۰	۰/۷۳	۰/۸۷	۰/۷۲
	BM25	۰/۶۰	۰/۸۰	۰/۸۷	۰/۷۲
	ترکیبی	۰/۷۳	۰/۸۰	۰/۸۷	۰/۷۹
اپتیک (۱۳ پرسش)	برداری	۰/۶۹	۱/۰۰	۱/۰۰	۰/۸۵
	BM25	۰/۹۲	۱/۰۰	۱/۰۰	۰/۹۶
	ترکیبی	۰/۶۹	۱/۰۰	۱/۰۰	۰/۸۳

در HITRAN، بازیابی ترکیبی بهترین نتیجه را داد. در مجموعه‌ی اپتیک، BM25 به‌تنهایی بهتر بود. علت احتمالی این است که پرسش‌های اپتیک نام ماده و نماد دقیق دارند و در مجموعه‌ای با سه مقاله، تطابق کلیدواژه تقریباً همیشه کافی است. در این حالت، افزودن فهرست برداری فقط نامزدهای نادرستی را به بالای فهرست ادغام‌شده می‌آورد.

۱.۲.۵ RAG در برابر مدل بدون منبع

جدول ۲.۵ پاسخ سامانه را با پاسخ همان مدل بدون منبع مقایسه می‌کند.

جدول ۲.۵: پاسخ به ۱۵ پرسش جواب‌دار و ۱ پرسش بی‌جواب HITRAN (`results/eval/hitran_answers.csv`).

سامانه	دقت (پرسش جواب‌دار)	«پیدا نشد» برای پرسش جواب‌دار	امتناع درست (پرسش بی‌جواب)
RAG + Qwen3-4B	۰/۹۳ (۱۴ از ۱۵)	۰/۰۰	۱/۰
Qwen3-4B بدون منبع	۰/۰۰	۱/۰۰	۱/۰

مدل کوچک بدون منبع در هیچ پرسشی عدد درست را نیاورد و همیشه گفت پاسخ را نمی‌داند. این رفتار از تولید عدد نادرست بهتر است، اما کاربرد عملی ندارد. با RAG، همان مدل در ۱۴ پرسش از ۱۵ پرسش مقدار درست را با منبع آورد. تنها خطا (پرسش h07) از نوع «دقت عددی» بود. منبع درست بازیابی شده بود، اما مدل به‌جای مقدار دقیق $5007.787078\ \mathrm{cm^{-1}}$ عدد تقریبی «حدود ۵۰۰۰ $\mathrm{cm^{-1}}$» را از مقدمه‌ی مقاله آورد.

۲.۲.۵ نمونه‌ی پاسخ‌ها

جدول ۳.۵ چند نمونه از پاسخ‌های واقعی ثبت‌شده در این آزمون را نشان می‌دهد (`results/eval/hitran_answers_details.csv`). پرسش‌ها به انگلیسی پرسیده شده‌اند و در اینجا ترجمه شده‌اند. پاسخ‌ها بی‌تغییر آمده‌اند.

جدول ۳.۵: نمونه‌ی پاسخ‌های ثبت‌شده در آزمون HITRAN.

پرسش	پاسخ RAG + Qwen3-4B	مدل بدون منبع
بر پایه‌ی محاسبات نظری، پهنای نیم‌بیشینه‌ی پهن‌شدگی خطوط CO_2 با بخار آب در مقایسه با پهن‌شدگی با هوا تا چه اندازه می‌تواند بزرگ شود؟	...can reach twice the values of the air-broadened half-widths [1].	Not found in the provided sources.
چه ضریب مقیاسی روی پارامترهای پهن‌شدگی با هوای CH_4 اعمال شد تا ضرایب پهن‌شدگی با بخار آب به دست آید؟	...was 1.36 [1].	Not found in the provided sources.
Sung و همکاران پهن‌شدگی با بخار آب را برای چند خط $^{12}CO_2$ گزارش کردند؟	182 lines ...in the ν_3 and $\nu_2+\nu_3-\nu_2$ bands [1].	Not found in the provided sources.
بازه‌ی ضرایب پهن‌شدگی H_2 که Padmanabhan و همکاران برای خطوط باند 00001←30012 اندازه گرفتند چیست؟	...from 0.095 cm^{-1}/atm for the P(32) line to 0.121 cm^{-1}/atm for the P(20) line [1].	Not found in the provided sources.
ضریب کالیبراسیون مقیاس عدد موج طیف‌های تبدیل فوریه‌ی CO_2 و H_2 چقدر بود؟	...was 1.000000467 [1].	Not found in the provided sources.
ضریب پهن‌شدگی خودی خط NH_3 در ۱/۲ میکرومتر در دمای ۱۵۰ کلوین چقدر است؟ (پرسش بی‌جواب)	Not found in the provided sources.	Not found in the provided sources.

دو نکته در این جدول دیده می‌شود. پاسخ RAG عدد را با همان دقت منبع می‌آورد، حتی وقتی عدد ۱۰ رقم معنادار دارد (1.000000467)، و شرایط اندازه‌گیری مانند نام خط و باند را هم حفظ می‌کند. پرسش آخر عمداً بی‌جواب طراحی شده بود: مقاله‌ای درباره‌ی NH_3 در مجموعه نبود و سامانه به‌جای ساختن عدد، «پیدا نشد» گفت.

۳.۲.۵ اثر پرسش فارسی

همان ۱۵ پرسش به فارسی نوشته و پس از ترجمه‌ی خودکار جست‌وجو شدند (جدول ۴.۵).

جست‌وجوی برداری از ترجمه اثر نپذیرفت، ولی BM25 که به واژه‌ی دقیق وابسته است افت کرد. این تفاوت با سازوکار دو روش سازگار است: ترجمه معنای پرسش را حفظ می‌کند ولی واژه‌ی دقیقی را که نویسنده‌ی مقاله به کار برده لزوماً تولید نمی‌کند. خطای شاخص ترجمه ابهام واژه‌ی «چند» بود: «چند خط» در دو پرسش به «several lines» ترجمه شد، در حالی که منظور «how many» بود.

این عددها روی مجموعه‌هایی با ۱۳ تا ۱۶ پرسش و سه مقاله به دست آمده‌اند. آن‌ها فقط نشان می‌دهند خط

جدول ۴.۵: همان ۱۵ پرسش HITRAN به فارسی، ترجمه با Qwen3-4B (results/eval/hitran_retrieval_fa.csv).

روش	MRR پرسش انگلیسی	MRR پرسش فارسی (پس از ترجمه)
برداری	۰/۷۲	۰/۷۲
BM25	۰/۷۲	۰/۶۳
ترکیبی	۰/۷۹	۰/۷۲

لوله و ابزار ارزیابی درست کار می‌کنند و برای نتیجه‌گیری کلی کافی نیستند. با ۱۵ پرسش، تغییر پاسخ تنها یک پرسش سنجه‌ی R@k را حدود ۷ درصد جابه‌جا می‌کند.

۳.۵ ارزیابی جست‌وجو روی مجموعه‌ی بزرگ

برای مجموعه‌ی ۲۸۴۵ سندی، بانک پرسش‌ها از سه منبع ساخته شد: پرسش‌های ساخته‌شده از داده‌های refractiveindex.info (گروه ri: «فرمول ضریب شکست ماده‌ی X از کدام مقاله است؟»)، پرسش‌هایی که مدل زبانی از متن مقاله‌ها نوشت (گروه gen)، و پرسش‌هایی از داده‌های آزموده‌ی پایگاه (گروه‌های dij، thermo و paper). ارزیابی روی سایت زنده اجرا شد. معیار برخورد، حضور مقاله‌ی طلایی در ۱۰ نتیجه‌ی اول است. جدول ۵.۵ نتیجه را نشان می‌دهد.

جدول ۵.۵: ارزیابی ۲۰۰ پرسش طلایی روی سایت زنده، ۴ آبان ۱۴۰۵ (scripts/quality/reports/search-2026-10-26.md). بازه‌ی اطمینان با بازنمونه‌گیری bootstrap (۵۰۰۰ بار) روی پرسش‌ها محاسبه شد.

روش	R@1	R@3	R@10	MRR@10	بازه‌ی اطمینان ۹۵ درصد
جست‌وجوی ترکیبی (ترتیب سایت)	۰/۴۳۰	۰/۵۹۵	۰/۶۹۵	۰/۵۱۸	۰/۴۶ تا ۰/۵۸
رتبه‌بندی دوم SubQ روی ۳۰ نامزد	۰/۵۰۰	۰/۶۵۵	۰/۷۴۵	۰/۵۹۰	۰/۵۳ تا ۰/۶۵

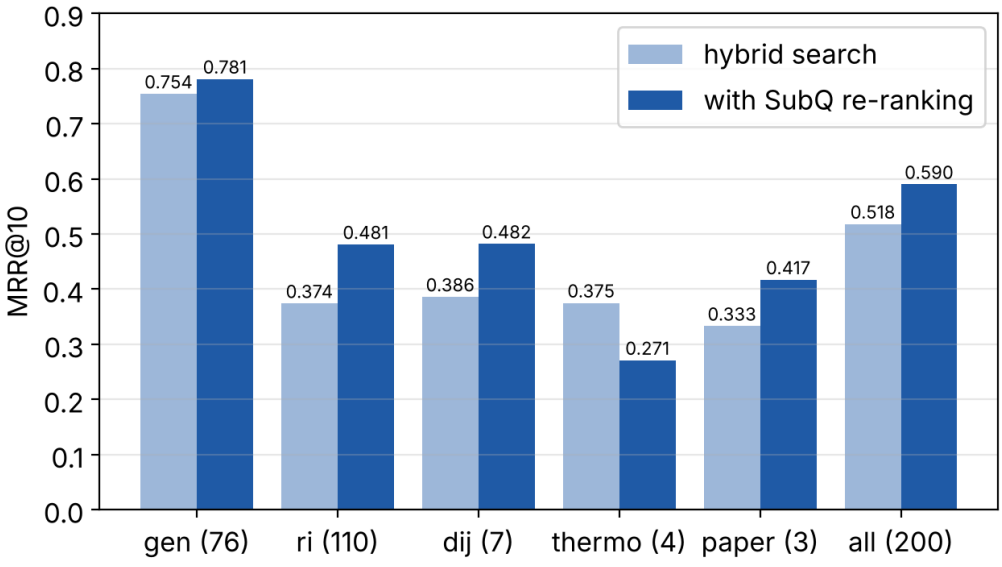
بهبود حاصل از رتبه‌بندی دوم برابر $0.071+$ است. بازه‌ی اطمینان ۹۵ درصد جفتی این تفاوت (بازنمونه‌گیری روی همان پرسش‌ها) از $0.027+$ تا $0.115+$ است و صفر را دربر نمی‌گیرد. پس این بهبود از نظر آماری معنادار است. توجه کنید که دو بازه‌ی جدول ۵.۵ با هم هم‌پوشانی دارند، اما این به معنای نبود تفاوت معنادار نیست: بازه‌ی جفتی دقیق‌تر است، چون دشواری پرسش‌ها در هر دو روش یکسان است و از تفاوت حذف می‌شود.

جدول ۶.۵ و شکل ۱.۵ همین نتیجه را به تفکیک گروه پرسش نشان می‌دهند.

پرسش‌هایی که از متن خود مقاله نوشته شده‌اند (gen) نتیجه‌ی خوبی دارند. این انتظار می‌رود، چون واژه‌های این پرسش‌ها از همان متن آمده‌اند. ضعیف‌ترین گروه بزرگ، ri است. در این گروه فقط مقاله‌ای درست حساب می‌شود که refractiveindex.info به آن ارجاع داده است، در حالی که اغلب چند مقاله‌ی دیگر مجموعه هم

جدول ۶.۵: MRR@10 به تفکیک گروه پرسش (همان ارزیابی جدول ۵.۵).

گروه	تعداد	ترکیبی	با SubQ
gen: پرسش نوشته‌شده از متن مقاله	۷۶	۰/۷۵۴	۰/۷۸۱
ri: مقاله‌ی منبع فرمول ضریب شکست	۱۱۰	۰/۳۷۴	۰/۴۸۱
dij: ضرایب غیرخطی	۷	۰/۳۸۶	۰/۴۸۲
thermo: ضریب ترمواپتیک	۴	۰/۳۷۵	۰/۲۷۱
paper: مقاله‌ی فرمول	۳	۰/۳۳۳	۰/۴۱۷
کل	۲۰۰	۰/۵۱۸	۰/۵۹۰



شکل ۱.۵: MRR@10 به تفکیک گروه پرسش در ارزیابی ۲۰۰ پرسشی؛ ستون کم‌رنگ جست‌وجوی ترکیبی و ستون پررنگ با رتبه‌بندی دوم SubQ. عدد داخل پرانتز تعداد پرسش‌های هر گروه است.

ضریب شکست همان ماده را اندازه گرفته‌اند. برای نمونه در پرسش YVO_4، مقاله‌های Zelmon 2010 و Zeng 1990 که هر دو اندازه‌گیری ضریب شکست YVO_4 هستند بالاتر از مقاله‌ی طلایی Lomheim 1978 آمدند. پس این سنجه عملکرد واقعی را کمتر از واقع نشان می‌دهد. گروه‌های dij، thermo و paper فقط ۳ تا ۷ پرسش دارند و عددشان برای نتیجه‌گیری کافی نیست؛ برای نمونه، افت گروه thermo با رتبه‌بندی دوم از تغییر رتبه‌ی یکی دو پرسش ناشی می‌شود.

۱.۳.۵ روند در طول پروژه

در گزارش اول به استاد راهنما (۱۳ مهر ۱۴۰۵) مجموعه ۲۶۲۳ مقاله و ۵۶۹۱۳ بخش داشت و MRR کل روی بانک ۷۱۷ پرسشی ۰/۴۵۵ بود. در یک ارزیابی دروازه‌ی کیفیت با ۸۰ پرسش روی سایت زنده (۲ آبان ۱۴۰۵)، MRR@10 جست‌وجوی ترکیبی ۰/۵۳۵ و با رتبه‌بندی دوم ۰/۶۱۳ بود. این عددها روی مجموعه‌های پرسش متفاوتی به دست آمده‌اند و مستقیماً با هم قابل‌مقایسه نیستند.

۴.۵ آزمایش‌های مقایسه‌ای

اثر هر تغییر، پیش از پذیرفته شدن در سامانه، به‌صورت کمّی اندازه‌گیری شد. تغییرهایی که نتیجه را بهتر نکردند، هرچند از نظر نظری موجه بودند، کنار گذاشته شدند. جدول ۷.۵ مهم‌ترین این آزمایش‌ها را نشان می‌دهد.

جدول ۷.۵: تغییرات مهم و اثر اندازه‌گیری‌شده‌ی آن‌ها.

تغییر	قبل	بعد	تصمیم
رتبه‌بند متقاطع bge-reranker-base روی ۳۰ نامزد (۲۰۰ پرسش، ۱۸ مهر)	۰/۴۳۹	۰/۴۰۱	کنار گذاشته شد
حذف بخش‌های کم‌ارزش با نقشه‌ی داده	۰/۵۱۱	۰/۴۸۵	کنار گذاشته شد
جست‌وجوی جداگانه روی نام ماده: تعداد «پیدا نشد»های اشتباه	۵۲	۱۳	نگه داشته شد
پیش‌واکشی متمرکز بر بلور (MRR)	۰/۵۱۸	۰/۵۳۸	نگه داشته شد
رتبه‌بندی دوم SubQ (ارزیابی ۸۰ پرسشی)	۰/۵۳۲	۰/۶۱۴	پیش‌فرض شد
بهینه‌سازی سرعت: زمان پاسخ جست‌وجو (ثانیه)	۲/۱ تا ۲/۹	۱/۱ تا ۱/۴	کیفیت بدون تغییر ماند

دو نکته در تفسیر این جدول مهم است. اول، رتبه‌بند bge در گروه ri افت شدید داشت (۰/۱۹۷ به ۰/۱۴۴) و در گروه gen تقریباً بی‌اثر بود (۰/۸۲۱ به ۰/۸۱۹). یک توضیح محتمل این است که این رتبه‌بند روی متن عمومی آموزش دیده و پرسش‌های گروه ri، که فقط نام ماده و «ضریب شکست» دارند، برایش اطلاعات کافی برای تمایز میان مقاله‌های هم‌موضوع فراهم نمی‌کنند. دوم، با توجه به بازه‌ی اطمینان حدود ± 0.06 در جدول ۵.۵، تفاوت‌های حدود ۰/۰۲ (مانند پیش‌واکشی بلور) در حد نوسان آماری‌اند و نمی‌توان با اطمینان گفت بهبود واقعی‌اند.

افزون بر این، این تنظیم‌ها روی همان پرسش‌هایی انجام شد که گزارش هم روی آن‌هاست، و این می‌تواند نتیجه را خوش‌بینانه کند.

۵.۵ درستی‌آزمایی فیزیکی

خروجی محاسبه‌گرها با عددهایی مقایسه شد که خود مقاله‌ها گزارش کرده‌اند (جدول ۸.۵). همه‌ی این موارد در کد به‌صورت آزمون خودکار وجود دارند.

جدول ۸.۵: خروجی سامانه در برابر عدد گزارش‌شده در مقاله‌ی اصلی.

آزمون	سامانه	مقاله
BBO، زاویه‌ی SHG نوع اول در ۱/۰۶۴ میکرومتر	۲۲/۸۳ درجه	۲۲/۸ درجه
GdCOB، زاویه در صفحه‌های xz و xy (Aka 1997)	۱۹/۶۸ و ۴۵/۹۹ درجه	۱۹/۶۸ و ۴۵/۹۹ درجه
$CdSiP_2$، SHG در ۴/۷۸۴۶ میکرومتر (Kato 2011)	۴۳/۱۴ درجه	۴۳/۱۳ درجه
d_{eff} بلورهای BBO و LBO (پیکومتر بر ولت)	۲/۰۲ و ۰/۸۳	۱/۹۴ و ۰/۸۲
d_{eff} بلورهای $LiInS_2$ و $LiInSe_2$ (Petrov 2010)	۶/۵۱ و ۹/۳۴	۶/۵۴ و ۹/۳۵
دوره‌ی QPM بلورهای PPLN و PPKTP برای SHG ۱/۰۶۴ میکرومتر (میکرومتر)	۶/۹ و ۹/۰	حدود ۶/۸ تا ۶/۹ و ۹/۰
PPKTP، SPDC با دمش ۴۰۵ نانومتر (Fedrizzi 2007 [۳۰])	۱۰/۰ میکرومتر در ۴۹/۲ درجه‌ی سانتی‌گراد	۱۰/۰ میکرومتر، حدود ۴۹ درجه
KTP، دمای NCPM سه فرایند (Kato 2002) (درجه‌ی سانتی‌گراد)	۶۳/۷۷ و ۷۷/۵۶ و ۵۹/۶۴	۶۳/۸ و ۷۷/۶ و ۵۹/۸
LBO، دمای NCPM برای SHG ۱/۰۶۴ میکرومتر (درجه‌ی سانتی‌گراد)	حدود ۱۴۹	۱۴۸ تا ۱۴۹/۵ (اندازه‌گیری)
CaF_2 (Leviton و همکاران)، ضریب شکست در ۰/۴۰ میکرومتر و ۲۹۵ کلوین	۱/۴۴۲۲۱	بازتولید تا رقم پنجم

آزمون منظم داده‌ها چند ناسازگاری را در خود ادبیات یا در نقل آن آشکار کرد: یک عدد تکراری در جدول ضرایب CBO، اختلاف ۰/۰۳ در n_x فرمول YCOB نسبت به جدول اندازه‌گیری همان مقاله، جابه‌جایی d_{31} و d_{32} در KTP و LBO میان قراردادهای مختلف محور، و نگاشت محورهای بلورشناسی به دی‌الکتریک در $LiInS_2$، $LiInSe_2$، BiBO و MNA. این یافته‌ها نشان می‌دهند که آزمون نظام‌مند داده‌ها در برابر عدد مقاله، افزون بر کنترل کیفیت، خود ارزش علمی مستقلی دارد.

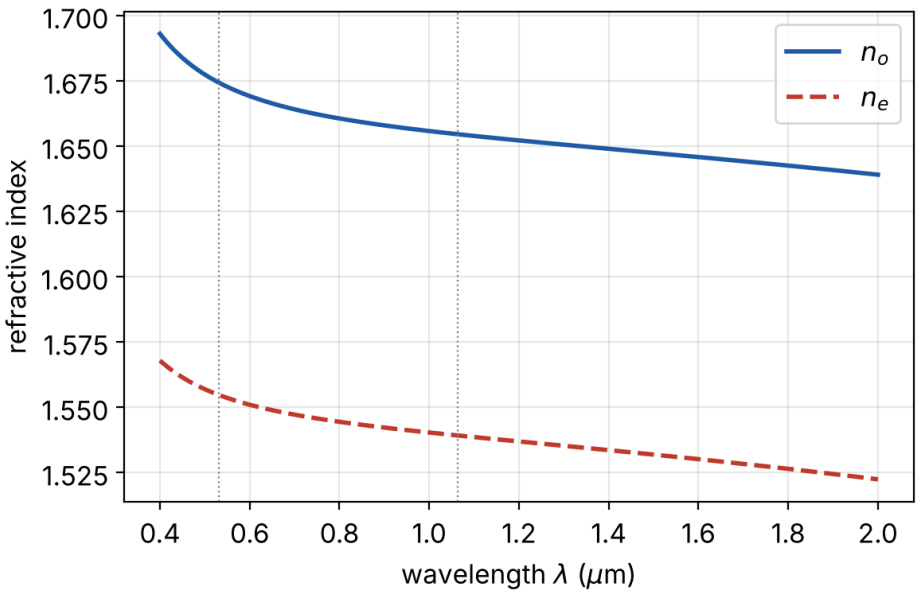
مشاور انتخاب بلور با ۱۵ سناریوی نمونه آزموده شد و در همه‌ی آن‌ها پیشنهادهای اول با انتخاب رایج متخصصان هم‌خوان بود: BBO و CLBO برای تولید فرابنفش، PPLN و PPKTP برای تبدیل در ناحیه‌ی مرئی، و GaSe، $ZnGeP_2$، $CdSiP_2$ و OP-GaAs برای فروسرخ میانی. این سناریوها را خود نگارنده ساخته است و آزمون با سناریوهای واقعی آزمایشگاه‌ها هنوز انجام نشده است.

۱.۵.۵ مثال حل‌شده: تولید هماهنگ دوم نوع اول در BBO

برای نشان دادن زنجیره‌ی محاسبه از داده تا نتیجه، تولید هماهنگ دوم لیزر Nd:YAG ($\lambda_\omega = 1.064\ \mu\text{m}$) در بلور تک‌محوری منفی BBO به‌طور کامل حل می‌شود. فرمول سلماير به‌کاررفته همان فرمولی است که در بسته‌ی مرجع پایتون پروژه برای BBO ثبت شده و از کار Eimerl و همکاران گرفته شده است [۳۱]:

$$\begin{aligned} n_o^2 &= 2.7359 + \frac{0.01878}{\lambda^2 - 0.01822} - 0.01354\,\lambda^2, \\ n_e^2 &= 2.3753 + \frac{0.01224}{\lambda^2 - 0.01667} - 0.01516\,\lambda^2. \end{aligned} \tag{۲.۵}$$

همه‌ی عددهای این بخش و بخش بعد با برنامه‌ی `scripts/calc_figures.py` (پیوست ج) دوباره محاسبه شدند و با عددهای ثبت‌شده در بسته‌ی مرجع پروژه یکسان‌اند. شکل ۲.۵ منحنی دو ضریب شکست را در ناحیه‌ی شفافیت نشان می‌دهد.



شکل ۲.۵: ضریب شکست عادی (n_o) و غیرعادی (n_e) بلور BBO از رابطه‌ی (۲.۵). خط‌چین‌های عمودی طول موج‌های ۰/۵۳۲ و ۱/۰۶۴ میکرومتر را نشان می‌دهند. دوشکستی منفی ($n_e < n_o$) شرط لازم تطبیق فاز نوع اول است.

گام ۱، ضرایب شکست. با λ بر حسب میکرومتر: $n_o(1.064) = 1.65452$، $n_o(0.532) = 1.67421$ و $n_e(0.532) = 1.55466$. به دلیل پاشندگی عادی، $n_o(0.532) > n_o(1.064)$ است و بدون استفاده از دوشکستی تطبیق فاز ممکن نیست.

گام ۲، زاویه‌ی تطبیق فاز. در برهم‌کنش نوع اول (ooe) باید $n_e(2\omega, \theta) = n_o(\omega)$ باشد. با ضریب شکست

غیرعادی وابسته به زاویه

$$\frac{1}{n_e^2(\theta)} = \frac{\cos^2\theta}{n_o^2} + \frac{\sin^2\theta}{n_e^2} \implies \sin^2\theta_{pm} = \frac{n_o(\omega)^{-2} - n_o(2\omega)^{-2}}{n_e(2\omega)^{-2} - n_o(2\omega)^{-2}}, \tag{۳.۵}$$

جای‌گذاری عددها $\theta_{pm} = 22.78^\circ$ را می‌دهد. سایت با فرمول پاشندگی خودش 22.83° و ادبیات 22.8° را گزارش می‌کنند. اختلاف حدود 0.05° از تفاوت فرمول‌های سلمایر منابع مختلف می‌آید و نشان می‌دهد که انتخاب منبع داده، حتی برای بلور جاافتاده‌ای مانند BBO، در رقم دوم اعشار زاویه اثر دارد.

گام ۳، طول همدوسی بدون تطبیق فاز. اگر نور در امتداد محور نوری ($\theta = 0$) منتشر شود، $\Delta k = (2\pi/\lambda_{2\omega})\,[n_o(2\omega) - n_o(\omega)] = 0.233\ \mu\mathrm{m}^{-1}$ و از رابطه‌ی (۱۸.۲) $L_c \approx 13.5\ \mu\mathrm{m}$. یعنی بدون تطبیق فاز، فقط چند ده میکرومتر از بلور در تولید هماهنگ دوم مؤثر است، در حالی که با تطبیق فاز طول مؤثر به چند میلی‌متر می‌رسد.

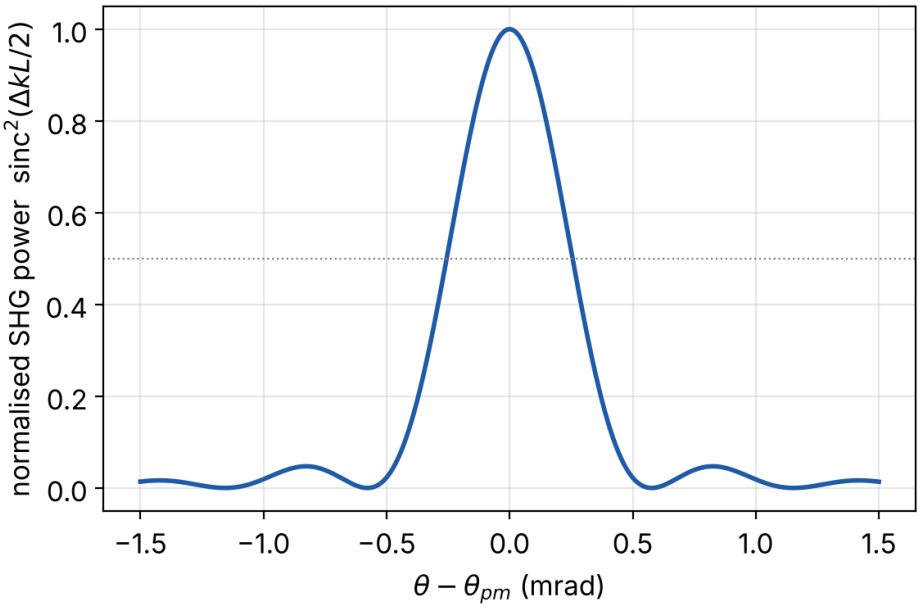
گام ۴، جدایی مسیر (walk-off). در بلور ناهمسانگرد، جهت انرژی موج غیرعادی با بردار موج زاویه‌ی ρ می‌سازد:

$$\tan(\theta + \rho) = \left(\frac{n_o}{n_e}\right)^2 \tan\theta, \tag{۴.۵}$$

که برای موج هماهنگ دوم $\rho = 3.19^\circ$ (۵۵/۶ میلی‌رادیان) را می‌دهد. برای باریکه‌ای با قطر ۱۰۰ میکرومتر، دو باریکه پس از حدود ۱/۸ میلی‌متر از هم جدا می‌شوند. همین کمیت طول مفید بلور را برای باریکه‌های کانونی‌شده محدود می‌کند.

گام ۵، پهنای پذیرش زاویه‌ای. مشتق عددی Δk نسبت به θ در زاویه‌ی تطبیق فاز $|\partial\Delta k/\partial\theta| = 1.09\ \mu\mathrm{m}^{-1}\,\mathrm{rad}^{-1}$ است و از رابطه‌ی (۱۹.۲) $\Delta\theta \cdot L \approx 0.51\ \mathrm{mrad}\cdot\mathrm{cm}$ به دست می‌آید. پس برای بلوری به طول ۱ سانتی‌متر، زاویه‌ی برش و تنظیم باید بهتر از حدود نیم میلی‌رادیان باشد. شکل ۳.۵ منحنی کامل $\mathrm{sinc}^2(\Delta k L/2)$ را بر حسب انحراف زاویه برای همین بلور نشان می‌دهد.

گام ۶، ضریب مؤثر. برای گروه نقطه‌ای $3m$ در برهم‌کنش ooe، $d_{\mathrm{eff}} = d_{31}\sin\theta - d_{22}\cos\theta\sin 3\varphi$. با مقادیر پایگاه ($|d_{22}| = 2.2$ و $d_{31} = 0.1$ پیکومتر بر ولت) و $\varphi = 90^\circ$، جمله‌ی غالب $d_{22}\cos\theta = 2.03\ \mathrm{pm/V}$ است و سهم $d_{31}\sin\theta$ فقط $0.04\ \mathrm{pm/V}$. سایت $2.02\ \mathrm{pm/V}$ را محاسبه می‌کند و مقدار اندازه‌گیری‌شده‌ی Eckardt و همکاران $1.94\ \mathrm{pm/V}$ است. جدول ۹.۵ نتیجه‌ها را خلاصه می‌کند.



شکل ۳.۵: توان بهنجار هماهنگ دوم بر حسب انحراف از زاویه‌ی تطبیق فاز در بلور BBO به طول ۱ سانتی‌متر (SHG نوع اول در ۱/۰۶۴ میکرومتر)، محاسبه‌شده از رابطه‌های (۱۷.۲) و (۲.۵). خط‌چین افقی نصف بیشینه را نشان می‌دهد؛ پهنای کامل منحنی در این تراز حدود ۰/۵ میلی‌رادیان است.

جدول ۹.۵: خلاصه‌ی مثال حل‌شده‌ی SHG نوع اول در BBO در ۱/۰۶۴ میکرومتر.

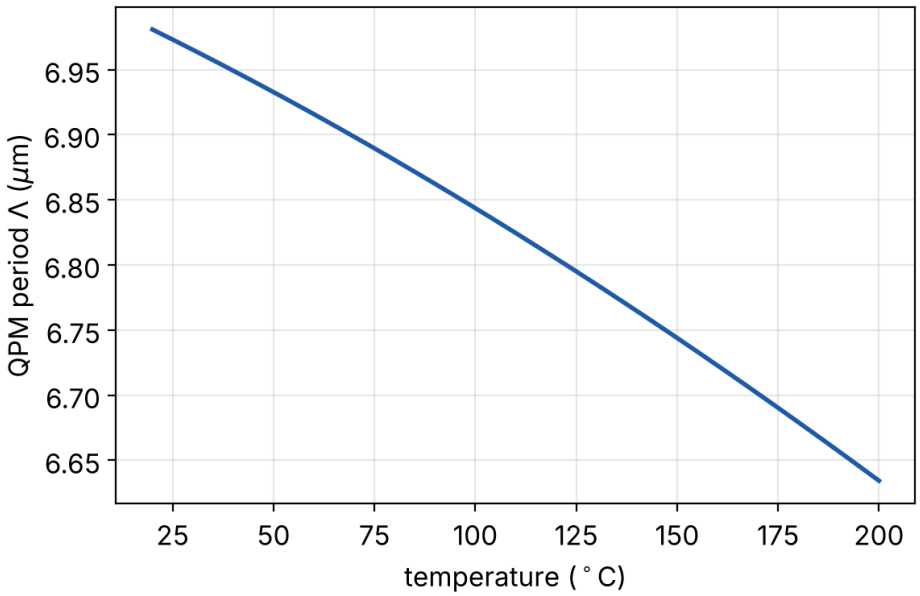
کمیت	مقدار محاسبه‌شده	مقایسه
زاویه‌ی تطبیق فاز θ_{pm}	۲۲/۷۸ درجه	سایت ۲۲/۸۳، ادبیات ۲۲/۸ درجه
طول همدوسی در $\theta = 0$	۱۳/۵ میکرومتر	-
زاویه‌ی walk-off	۳/۱۹ درجه (۵۵/۶ میلی‌رادیان)	-
پهنای پذیرش زاویه‌ای $\Delta\theta \cdot L$	۰/۵۱ میلی‌رادیان سانتی‌متر	-
d_{eff}	۲/۰۳ پیکومتر بر ولت	سایت ۲/۰۲، اندازه‌گیری ۱/۹۴

۲.۵.۵ مثال حل‌شده: تطبیق فاز شبه‌فازی در PPLN

در لیتیم نیوبات قطبیده‌ی دوره‌ای، هر سه موج با قطبش غیرعادی منتشر می‌شوند تا از بزرگ‌ترین ضریب، d_{33}، استفاده شود. در این هندسه تطبیق فاز دوشکستی ممکن نیست و ناهمخوانی فاز با وارون کردن دوره‌ای قطبش جبران می‌شود. برای SHG دوره‌ی لازم برابر است با

$$\Lambda = \frac{2\pi}{\Delta k} = \frac{\lambda_\omega}{2\,[n_e(2\omega) - n_e(\omega)]}. \tag{۵.۵}$$

با فرمول وابسته به دمای Gayer و همکاران برای لیتیم نیوبات آلاییده با MgO [۳۲]، در دمای ۲۵ درجه‌ی سانتی‌گراد $n_e(1.064) = 2.14829$ و $n_e(0.532) = 2.22458$ است و $\Lambda = 6.97\ \mu\mathrm{m}$ به دست می‌آید. در دمای ۱۰۰ درجه، دوره به $6.84\ \mu\mathrm{m}$ می‌رسد. شکل ۴.۵ این وابستگی را در بازه‌ی ۲۰ تا ۲۰۰ درجه نشان می‌دهد. این وابستگی دمایی همان چیزی است که در عمل برای تنظیم دقیق تطبیق فاز با دمای آون به کار می‌رود: بلور با دوره‌ی ثابت ساخته می‌شود و دمای آون طوری تنظیم می‌شود که دوره‌ی لازم با دوره‌ی ساخته‌شده یکی شود. مقدار گزارش‌شده‌ی سایت $6.9\ \mu\mathrm{m}$ و مقدار رایج ادبیات 6.8 تا $6.9\ \mu\mathrm{m}$ است.



شکل ۴.۵: دوره‌ی تطبیق فاز شبه‌فازی مرتبه‌ی اول برای تولید هماهنگ دوم ۱/۰۶۴ میکرومتر در لیتیم نیوبات آلاییده با MgO، بر حسب دما، از رابطه‌ی (۵.۵) و فرمول Gayer و همکاران.

ضریب مؤثر از رابطه‌ی (۱۶.۲) با مقدار $|d_{33}| = 25.0\ \mathrm{pm/V}$ که پایگاه از کار Shoji و همکاران ثبت کرده است، برابر $d_{\mathrm{eff}} = (2/\pi)|d_{33}| \approx 15.9\ \mathrm{pm/V}$ است، یعنی نزدیک به هشت برابر BBO. چون بازده تبدیل با d_{eff}^2 متناسب است (رابطه‌ی (۱۷.۲))، این به معنای بازده‌ای حدود ۶۰ برابر در طول بلور یکسان است، اگر از تفاوت ضرایب شکست در مخرج رابطه چشم‌پوشی شود. این مقایسه دلیل اصلی کاربرد گسترده‌ی PPLN در تبدیل طول

موج در ناحیه‌ی مرئی و فروسرخ نزدیک است.

۶.۵ استخراج خودکار فرمول: یک نتیجه‌ی منفی

استخراج خودکار ضرایب فرمول پاشندگی با مدل زبانی روی ۲۴ مقاله آزموده شد و ضریب شکست حاصل با مدخل همان مقاله در refractiveindex.info مقایسه شد. در هیچ موردی ضریب شکست محاسبه‌شده تا دقت ۰/۰۱ با مرجع یکی نبود. فرمول پاشندگی به همه‌ی ضرایب، توان‌ها، علامت‌ها و واحد طول موج حساس است و یک خطای کوچک در هر کدام کل منحنی را جابه‌جا می‌کند. برای نمونه، اگر C_i در رابطه‌ی (۱۰.۲) به‌جای مربع طول موج تشدید، خود طول موج تشدید خوانده شود، یا طول موج به‌جای میکرومتر بر حسب نانومتر وارد شود، منحنی حاصل از نظر شکل هم با منحنی درست تفاوت دارد. این نتیجه شیوه‌ی کار بعدی پروژه را تعیین کرد: استخراج نیمه‌دستی و سپس آزمون با عدد مقاله (بخش ۳-۷).

در یک ممیزی خودکار بعدی، مقدار هر داده‌ی محاسبه‌گر کنار بخش منبعش گذاشته و با مدل زبانی سنجیده شد. ده موردی که کمترین امتیاز را گرفتند دستی بازبینی شدند و هیچ عدد اشتباهی پیدا نشد. علت امتیاز پایین، جدول‌های خراب یا تصویری و نگاشت عمدی محورها بود. این نتیجه نشان می‌دهد که مدل زبانی برای «بازبینی» یک عدد موجود در کنار منبعش ابزار مفیدتری است تا برای «تولید» آن عدد.

۷.۵ تحلیل خطا

خطاهای مشاهده‌شده در پنج دسته جای می‌گیرند:

۱. **دقت عددی:** منبع درست است، ولی مدل عدد گردشده‌ی مقدمه را به‌جای عدد دقیق جدول می‌آورد (پرسش h07).

۲. **ترجمه:** ابهام واژه‌های فارسی مانند «چند»، و ترجمه‌ی تحت‌اللفظی اصطلاحات (که با واژه‌نامه کاهش یافت).

۳. **کیفیت متن منبع:** جدول‌های تکه‌شده (۴۱ درصد جدول‌ها هنگام بخش‌بندی دو یا چند تکه شده بودند)، اسکن‌های قدیمی و معادله‌های تصویری.

۴. **ارزیابی ناقص:** در پرسش‌های ri، مقاله‌های دیگری که همان داده را دارند غلط شمرده می‌شوند. بازبینی نشان داد که بخش درخور توجهی از «خطا»های رتبه‌ی اول در این گروه در واقع مقاله‌ی مرتبط‌اند.

۵. **نگهبان «پیدا نشد»:** در یک ارزیابی پیشین، ۹ پرسش از ۴۰ پرسش بی‌جواب رد نشدند و سامانه برایشان منبع نامرتبط نشان داد.

از این پنج دسته، دسته‌ی اول و دوم به مدل زبانی، دسته‌ی سوم به مرحله‌ی تبدیل سند، دسته‌ی چهارم به روش ارزیابی و دسته‌ی پنجم به آستانه‌های نگهبان مربوط‌اند. پس بهبود سامانه به یک جزء خاص محدود نیست و هر جزء سهم جداگانه‌ای در خطای نهایی دارد.

فصل ۶

بحث، محدودیت‌ها و نتیجه‌گیری

۱.۶ پاسخ به پرسش‌های پژوهش

پرسش ۱ (RAG در برابر مدل بدون منبع). در مجموعه‌ی آزمایشی HITRAN، RAG دقت پاسخ عددی مدل Qwen3-4B را از صفر به ۱۴ پرسش از ۱۵ پرسش رساند و امتناع درست در پرسش بی‌جواب حفظ شد. این نتیجه روی مجموعه‌ی کوچکی به دست آمده است، اما جهت اثر روشن است: برای عددهای کم‌تکرار ادبیات تخصصی، مدل کوچک بدون منبع کاربردی نیست. تنها خطای باقی‌مانده نیز از نوع خواندن بود و نه بازیابی، که نشان می‌دهد در این مجموعه گلوگاه اصلی، دقت مدل در انتخاب عدد درست از میان بخش‌های بازیابی‌شده است.

پرسش ۲ (روش بازیابی). هیچ روش واحدی در همه‌ی حوزه‌ها برتر نبود. در HITRAN ترکیب برداری و BM25 بهترین بود و در مجموعه‌ی کوچک اپتیک BM25 به‌تنهایی. در مجموعه‌ی بزرگ، جست‌وجوی ترکیبی پایه‌ی سامانه ماند و تنها بهبود معنادار آماری از رتبه‌بندی دوم با مدل داور به دست آمد (۰/۵۱۸ به ۰/۵۹۰، با بهبود جفتی ۰/۰۲۷ تا ۰/۱۱۵ در بازه‌ی اطمینان ۹۵ درصد). رتبه‌بند متقاطع عمومی bge-reranker نتیجه را بدتر کرد. این یافته با این دیدگاه سازگار است که مدل‌های آموزش‌دیده روی متن عمومی بدون آزمون مستقل به متن علمی تخصصی تعمیم نمی‌یابند.

پرسش ۳ (پرسش فارسی). مسیر ترجمه برای جست‌وجوی برداری بی‌هزینه بود، ولی BM25 و در نتیجه جست‌وجوی ترکیبی را تضعیف کرد (MRR ترکیبی از ۰/۷۹ به ۰/۷۲). واژه‌نامه‌ی ثابت اصطلاحات فیزیک بخشی از خطاهای ترجمه را رفع کرد.

پرسش ۴ (استخراج خودکار). پاسخ منفی است. در ۲۴ مقاله‌ی آزموده، هیچ فرمول پاشندگی‌ای که مدل زبانی به‌طور خودکار استخراج کرد تا دقت ۰/۰۱ درست نبود. داده‌ی دقیق تنها با استخراج نیمه‌دستی و آزمون با عدد خود مقاله به دست آمد. سه بررسی خودکار (عدد در متن، شاهد عینی و بازه‌ی فیزیکی) جلوی عددسازی آشکار را می‌گیرند، ولی خطای خواندن ضرایب را نمی‌گیرند، زیرا ضریبی که از ستون اشتباه خوانده شده هم «در

متن منبع هست» و هم در بازه‌ی معقول قرار دارد.

۲.۶ محدودیت‌ها

ارزیابی

- بازه‌ی اطمینان MRR در ارزیابی ۲۰۰ پرسشی حدود ± 0.06 است. تفاوت‌های کوچک‌تر از این (مانند اثر پیش‌واکشی بلور) قابل‌اتکا نیستند.
- تنظیم سامانه و گزارش نتیجه روی یک مجموعه‌ی پرسش انجام شد و مجموعه‌ی آزمون جداگانه‌ای کنار گذاشته نشد. پس عددهای گزارش‌شده احتمالاً کمی خوش‌بینانه‌اند.
- داوری مرتبط بودن کامل نیست: هر پرسش فقط یک یا چند مقاله‌ی «طلایی» دارد، و مقاله‌های دیگری که همان داده را دارند غلط شمرده می‌شوند. برای داوری نهایی، داوری درجه‌بندی‌شده (همه‌ی مقاله‌هایی که به پرسش پاسخ می‌دهند) لازم است.
- گروه‌های ترمواپتیک، ضرایب d و مقاله‌ی فرمول فقط ۳ تا ۷ پرسش دارند.
- پاسخ نوشتاری فقط روی مجموعه‌ی آزمایشی HITRAN (۱۶ پرسش) ارزیابی شد. ارزیابی وفاداری پاسخ با RAGAS، مقایسه‌ی دو مدل برداری و اثر اندازه‌ی بخش‌ها، که در برنامه‌ی اولیه بود، انجام نشد.
- ارزیابی با کاربر واقعی انجام نشده و سناریوهای مشاور بلور ساخته‌ی خود نگارنده‌اند.

داده و مجموعه

- ۵۹۸ سند (۲۱ درصد) فقط چکیده دارند و ۳۳ سند فقط مشخصات. حدود ۴۳ فایل PDF مقاله‌ی دیگری را در خود دارند و ۴۷ مقاله‌ی اسکن‌شده‌ی قدیمی متن خراب دارند.
- مدل ترمواپتیک فقط برای ۶۷ بلور از ۱۸۶ بلور محاسبه‌گر وجود دارد و تانسور d برای چند بلور ناقص است.
- مجموعه به‌روزرسانی خودکار ندارد و فقط با دخالت دستی بزرگ می‌شود.

روش و زیرساخت

- مدل برداری فقط انگلیسی است و پرسش فارسی از مسیر ترجمه می‌گذرد.

- محاسبه‌ی تطبیق فاز (به‌جز بخش SPDC) در تقریب موج تخت است. بازده تبدیل با کانونی‌سازی، انتشار تپ و اثرهای گرمایی مدل نشده‌اند.
- رتبه‌بندی دوم و بخشی از برچسب‌زنی به اعتبار رایگان سرویس‌های بیرونی وابسته است. بدون آن، کیفیت جست‌وجو به حالت ترکیبی برمی‌گردد. پردازش سنگین هم در Colab رایگان انجام شد که پایدار نیست.
- به دلیل حق نشر متن مقاله‌ها، سایت عمومی نیست و تکرار کامل نتایج به دسترسی به همان مجموعه‌ی PDF نیاز دارد. کد، پرسش‌های مرجع، گزارش‌های ارزیابی و داده‌ی فیزیکی استخراج‌شده در مخزن عمومی هست.

۳.۶ کارهای آینده

۱. ساخت مجموعه‌ی ارزیابی بزرگ‌تر با داوری درجه‌بندی‌شده، دست‌کم ۳۰ پرسش برای هر گروه داده، و یک مجموعه‌ی آزمون جدا که در تنظیم سامانه استفاده نشود.

۲. استخراج نیمه‌خودکار با تأیید انسانی: مدل زبانی جدول‌های حاوی pm/V و dn/dT را پیشنهاد کند و انسان تأیید کند، با همان آزمون «عدد مقاله» به‌عنوان دروازه‌ی ورود.

۳. استفاده از یک مدل برداری چندزبانه برای پرسش فارسی بدون واسطه‌ی ترجمه.

۴. گسترش مدل فیزیکی: بازده تبدیل با کانونی‌سازی Boyd-Kleinman [۱۷] و پهنای پذیرش تپی.

۵. آزمودن مشاور بلور با سناریوهای واقعی آزمایشگاه‌های دانشگاه.

۶. تکمیل مسیر HITRAN: ساخت مجموعه‌ی مرجع نهایی با ۵۰ تا ۱۰۰ نمونه‌ی بررسی‌شده و یکسان‌سازی واحدها.

۴.۶ نتیجه‌گیری

در این پروژه یک سامانه‌ی RAG برای بازیابی اطلاعات و استخراج خواص فیزیکی مواد از مقاله‌های علمی طراحی، پیاده‌سازی و ارزیابی شد. سامانه از مقاله‌ی PDF تا پاسخ مستند با شماره‌ی صفحه و محل روی صفحه کار می‌کند، پرسش فارسی را می‌پذیرد و در نبود شاهد صریحاً «پیدا نشد» می‌گوید. روی مجموعه‌ای با ۲۸۴۵ سند و ۶۸۱۹۰ بخش، جست‌وجوی ترکیبی با رتبه‌بندی دوم در ۷۴/۵ درصد پرسش‌ها مقاله‌ی طلایی را در ۱۰ نتیجه‌ی اول آورد.

مهم‌ترین درس پروژه این است که در کار فیزیکی، RAG ابزار **یافتن منبع** است و نه جایگزین خواندن آن. مدل زبانی منبع درست را خوب پیدا می‌کند، ولی ضرایب یک فرمول را به‌طور قابل‌اتکا نمی‌خواند. ترکیب بازیابی

خودکار با آزمون هر عدد در برابر مقدار گزارش‌شده در خود مقاله، پایگاه داده‌ای ساخت که محاسبه‌هایش با ادبیات هم‌خوان است و در مسیر ساختش چند ناسازگاری در خود ادبیات هم آشکار شد. این الگو، یعنی «بازیابی خودکار، خواندن انسانی، آزمون خودکار»، به حوزه‌های دیگر فیزیک که داده‌ی پایه‌شان در مقاله‌ها پراکنده است نیز قابل‌انتقال است.

پیوست آ

واژه‌نامه

جدول آ.۱: واژه‌نامه‌ی فارسی به انگلیسی اصطلاحات گزارش.

فارسی	انگلیسی	توضیح
تولید تقویت‌شده با بازیابی	Retrieval-Augmented Generation (RAG)	پاسخ مدل زبانی بر پایه‌ی متن منابع بازیابی‌شده
پایگاه داده‌ی برداری	Vector database	ذخیره و جست‌وجوی سریع بردارهای معنایی
نمایش برداری، بردارسازی	Embedding	نگاشت متن به بردار عددی
بخش	Chunk	واحد جست‌وجو: یک پاراگراف، جدول یا تکه‌ی جدول
بازیابی ترکیبی	Hybrid retrieval	ترکیب جست‌وجوی برداری و کلیدواژه‌ای
ادغام معکوس رتبه	Reciprocal Rank Fusion (RRF)	رابطه‌ی (۷.۲)
رتبه‌بندی دوم	Re-ranking	مرتب‌سازی دوباره‌ی نامزدهای اول با مدل دقیق‌تر
توهم	Hallucination	تولید محتوای باورپذیر ولی نادرست توسط مدل زبانی
نویسه‌خوانی نوری	OCR	تبدیل تصویر صفحه به متن
فرمول پاشندگی (سلمایر)	Dispersion (Sellmeier) formula	رابطه‌ی (۱۰.۲)
تطبیق فاز	Phase matching	رابطه‌ی (۱۵.۲)
تطبیق فاز شبه‌فازی	Quasi-phase matching (QPM)	رابطه‌ی (۱۶.۲)
جدایی مسیر	Walk-off	رابطه‌ی (۴.۵)
فروتبدیل پارامتری خودبه‌خودی	SPDC	منبع جفت فوتون درهم‌تنیده
میانگین معکوس رتبه	Mean Reciprocal Rank (MRR)	رابطه‌ی (۱.۵)

اصطلاحات اصلی گزارش در جدول آ.۱ آمده‌اند. همین واژه‌نامه، با افزودن اصطلاحات بیشتر، در ترجمه‌ی پرسش‌های فارسی به مدل زبانی داده می‌شود (بخش ۳-۵-۳).

پیوست ب

منشأ عددهای گزارش

هر عدد این گزارش از یکی از فایل‌های زیر در مخزن کد پروژه آمده است:

- ترکیب مجموعه، بخش‌ها و چارک مجله‌ها: شمارش مستقیم پایگاه Qdrant و تطبیق مشخصات OpenAlex با فهرست SCImago، ۳ آبان ۱۴۰۵ (docs/matrag_report_aban1405.html).
- آزمون‌های اولیه: results/eval/ در مخزن کد.
- ارزیابی ۲۰۰ پرسشی: scripts/quality/reports/search-2026-10-26.md و فایل .json همراه آن. بازه‌های اطمینان با bootstrap روی همین فایل محاسبه شد.
- رتبه‌بند bge: docs/reranker_eval.md.
- داده‌ی فیزیکی: data/rag-optics/nonlinear_coefficients.yml، thermo_optic.yml، paper_formulas.yml و crystal_properties.yml.
- مثال‌های حل‌شده‌ی بخش ۵-۵ و شکل‌های ۲.۵، ۳.۵ و ۴.۵: برنامه‌ی scripts/calc_figures.py همراه این پایان‌نامه. شکل ۱.۵ با همین برنامه از عددهای جدول ۶.۵ رسم شده است.

پیوست پ

اجرای سامانه

فرمان‌های زیر سامانه را نصب، ارزیابی و اجرا می‌کنند. آزمون‌ها بدون اینترنت و بدون مدل زبانی اجرا می‌شوند.

```
pip install -e ".[dev]"
matrag --corpus hitran add 1906.01475                    # add a paper from arXiv
matrag --corpus hitran evaluate retrieval      # Recall@k and MRR, three retrieval
modes
matrag --corpus hitran evaluate answers     # RAG vs. LLM alone, "not found" test
matrag reference hitran results.csv --molecule CO2 --nu-min 5007.7 --nu-max
5007.9
matrag app                                          # web UI at http://127.0.0.1:7860
pytest                                                      # tests (offline, no LLM)
```

عددهای مثال‌های حل‌شده و نمودارهای فصل ۵ با فرمان زیر دوباره ساخته می‌شوند:

```
python3 scripts/calc_figures.py
```

منابع و مآخذ

[1] Z. Ji *et al.*, "Survey of hallucination in natural language generation," *ACM Comput. Surv.*, vol. 55, no. 12, art. 248, 2023.

[2] P. Lewis *et al.*, "Retrieval-augmented generation for knowledge-intensive NLP tasks," in *Advances in Neural Information Processing Systems*, vol. 33, pp. 9459–9474, 2020.

[3] M. N. Polyanskiy, "Refractiveindex.info database of optical constants," *Sci. Data*, vol. 11, art. 94, 2024.

[4] I. E. Gordon *et al.*, "The HITRAN2020 molecular spectroscopic database," *J. Quant. Spectrosc. Radiat. Transf.*, vol. 277, art. 107949, 2022.

[5] A. Vaswani *et al.*, "Attention is all you need," in *Advances in Neural Information Processing Systems*, vol. 30, pp. 5998–6008, 2017.

[6] Y. Gao *et al.*, "Retrieval-augmented generation for large language models: A survey," arXiv:2312.10997, 2023.

[7] N. Reimers and I. Gurevych, "Sentence-BERT: Sentence embeddings using Siamese BERT-networks," in *Proc. EMNLP-IJCNLP*, pp. 3982–3992, 2019.

[8] V. Karpukhin *et al.*, "Dense passage retrieval for open-domain question answering," in *Proc. EMNLP*, pp. 6769–6781, 2020.

[9] S. Xiao, Z. Liu, P. Zhang, and N. Muennighoff, "C-Pack: Packaged resources to advance general Chinese embedding," arXiv:2309.07597, 2023.

[10] Y. A. Malkov and D. A. Yashunin, “Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs,” *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 42, no. 4, pp. 824–836, 2020.

[11] S. Robertson and H. Zaragoza, “The probabilistic relevance framework: BM25 and beyond,” *Found. Trends Inf. Retr.*, vol. 3, no. 4, pp. 333–389, 2009.

[12] G. V. Cormack, C. L. A. Clarke, and S. Büttcher, “Reciprocal rank fusion outperforms Condorcet and individual rank learning methods,” in *Proc. 32nd ACM SIGIR*, pp. 758–759, 2009.

[13] R. Nogueira and K. Cho, “Passage re-ranking with BERT,” arXiv:1901.04085, 2019.

[14] A. Yariv and P. Yeh, *Optical Waves in Crystals*. New York: Wiley, 1984.

[15] R. W. Boyd, *Nonlinear Optics*, 3rd ed. Burlington, MA: Academic Press, 2008.

[16] J. A. Armstrong, N. Bloembergen, J. Ducuing, and P. S. Pershan, “Interactions between light waves in a nonlinear dielectric,” *Phys. Rev.*, vol. 127, no. 6, pp. 1918–1939, 1962.

[17] G. D. Boyd and D. A. Kleinman, “Parametric interaction of focused Gaussian light beams,” *J. Appl. Phys.*, vol. 39, no. 8, pp. 3597–3639, 1968.

[18] R. S. Bennink, “Optimal collinear Gaussian beams for spontaneous parametric down-conversion,” *Phys. Rev. A*, vol. 81, art. 053805, 2010.

[19] M. C. Swain and J. M. Cole, “ChemDataExtractor: A toolkit for automated extraction of chemical information from the scientific literature,” *J. Chem. Inf. Model.*, vol. 56, no. 10, pp. 1894–1904, 2016.

[20] A. Jain *et al.*, “Commentary: The Materials Project: A materials genome approach to accelerating materials innovation,” *APL Mater.*, vol. 1, art. 011002, 2013.

[21] V. G. Dmitriev, G. G. Gurzadyan, and D. N. Nikogosyan, *Handbook of Nonlinear Optical Crystals*, 3rd ed. Berlin: Springer, 1999.

[22] D. N. Nikogosyan, *Nonlinear Optical Crystals: A Complete Survey*. New York: Springer, 2005.

[23] M. D. Skarlinski *et al.*, "Language agents achieve superhuman synthesis of scientific knowledge," arXiv:2409.13740, 2024.

[24] S. Es, J. James, L. Espinosa-Anke, and S. Schockaert, "RAGAS: Automated evaluation of retrieval augmented generation," arXiv:2309.15217, 2023.

[25] R. V. Kochanov *et al.*, "HITRAN Application Programming Interface (HAPI): A comprehensive approach to working with spectroscopic data," *J. Quant. Spectrosc. Radiat. Transf.*, vol. 177, pp. 15–30, 2016.

[26] C. Auer *et al.*, "Docling technical report," arXiv:2408.09869, 2024.

[27] A. Yang *et al.* (Qwen Team), "Qwen3 technical report," arXiv:2505.09388, 2025.

[28] D. A. Roberts, "Simplified characterization of uniaxial and biaxial nonlinear optical crystals: A plea for standardization of nomenclature and conventions," *IEEE J. Quantum Electron.*, vol. 28, no. 10, pp. 2057–2074, 1992.

[29] B. Efron and R. J. Tibshirani, *An Introduction to the Bootstrap*. New York: Chapman & Hall, 1993.

[30] A. Fedrizzi, T. Herbst, A. Poppe, T. Jennewein, and A. Zeilinger, "A wavelength-tunable fiber-coupled source of narrowband entangled photons," *Opt. Express*, vol. 15, no. 23, pp. 15377–15386, 2007.

[31] D. Eimerl, L. Davis, S. Velsko, E. K. Graham, and A. Zalkin, "Optical, mechanical, and thermal properties of barium borate," *J. Appl. Phys.*, vol. 62, no. 5, pp. 1968–1983, 1987.

[32] O. Gayer, Z. Sacks, E. Galun, and A. Arie, "Temperature and wavelength dependent refractive index equations for MgO-doped congruent and stoichiometric $LiNbO_3$," *Appl. Phys. B*, vol. 91, pp. 343–348, 2008.

Abstract

Basic materials data such as refractive-index dispersion formulas, second-order nonlinear coefficients, thermo-optic coefficients and spectral line parameters are scattered across the tables and equations of thousands of papers, and general-purpose large language models often invent such numbers without a verifiable source. This project designed and implemented a retrieval-augmented generation (RAG) system that converts PDF papers into structured text and tables, indexes them in vector databases (ChromaDB locally, Qdrant for the web site), and answers Persian or English questions with a citation to the paper, page and location on the page. Retrieval is hybrid: dense search with bge-base-en-v1.5 embeddings and BM25 keyword search fused by reciprocal rank fusion. Structured property extraction comes with three automatic checks: the value is present in the source, the quoted evidence is verbatim, and the value lies in a physically plausible range.

The system was first tested on molecular spectroscopy with HITRAN as ground truth and then extended to linear and nonlinear optical crystals, with a final collection of 2,845 documents, 2,214 of them in full text, split into 68,190 searchable passages. On the HITRAN pilot set, RAG with a local Qwen3-4B model gave the correct value for 14 of 15 questions, while the same model without sources gave none. On 200 gold questions over the large collection, MRR@10 was 0.518 for hybrid search and 0.590 after LLM re-ranking of the top 30 (paired 95% bootstrap interval of the gain: +0.027 to +0.115). A tested physical database and calculators for phase matching and photon-pair generation were built on top; their outputs agree with values reported in the original papers, for example a type-I SHG phase-matching angle of 22.83° in BBO at 1.064 μm against 22.8° in the literature. A key negative result is that fully automatic extraction of formula coefficients by a language model did not reach the needed accuracy; accurate data required semi-manual extraction checked against each paper's own reported values.

Keywords: retrieval-augmented generation, vector database, hybrid retrieval, materials property extraction, refractive index, nonlinear optics, phase matching

University of Isfahan

Faculty of Physics

B.Sc. Physics Project Report (3 credits)

Design and Implementation of an Intelligent Information Retrieval and Materials Property Extraction System for Scientific Papers Using RAG Architecture and Vector Databases

Student: Amin Hossein Sadidi (Student ID: 4024213027)

Supervisor: Dr. Mohammadi

November 2026